프로젝트 방법을 이해하는 공부책

MediFlow 의료 이미지 AI · 로봇팔 · LLM/VLM
원리, 코드의 변화, 실제 결과와 발표 설명을 연결하는 학습 자료
2026-10-28

이 책의 목표

왜 미세조정을 했는지, SupCon·PMG는 무엇을 바꿨는지, 로봇팔은 사진을 보고 어떻게 움직이는지, LLM의 LoRA는 이미지 모델의 미세조정과 어떻게 다른지 스스로 설명할 수 있도록 구성했다. Python 문법을 모두 아는 것을 전제로 하지 않는다.

근거를 읽는 세 가지 구분

의료 AI의 결과는 로컬 코드·JSON·CSV와 문서에 저장된 값이다. 로봇팔은 70장 발표자료에 보고된 범위이며 원본 로봇 로그 전체를 이번에 재실행하지 않았다. LLM/VLM은 2026-10-26 고정 커밋 점검 기록을 기준으로, 팀원의 완료 결과와 우리 과제의 향후 실험을 구분한다.

숫자와 예시

프로젝트 성능표는 원본 기록을 사용한다. 원리를 설명하기 위해 만든 숫자나 JSON은 설명용 가상 예시라고 표시한다. 같은 이름의 방법이어도 원논문 전체를 동일하게 재현한 것과 핵심 아이디어를 응용한 것은 다르다.

발표에서는 이렇게

이 책의 중심 질문은 "무엇을 바꿨고, 왜 바꿨으며, 결과가 그 가설을 얼마나 뒷받침하는가?"이다.

근거: 내부 D01~D07. 원본 자료와 모델은 수정하지 않았다.

목차

제목 옆 숫자는 실제 PDF 페이지다. 본편의 출처 번호는 뒤의 논문·문서 목록과 연결된다.

시작하기	어떤 순서로 공부하면 좋을까	5
1. 공통 기초	네 가지 AI 과제부터 구분하기	6
1. 공통 기초	세 도메인과 클래스의 정확한 의미	7
1. 공통 기초	학습은 숫자를 바꾸고 추론은 답을 낸다	8
1. 공통 기초	전이·미세조정·모방·강화학습 구분하기	9
1. 공통 기초	데이터 버전과 분할을 먼저 읽기	10
1. 공통 기초	중복 검사와 데이터 누수	11
1. 공통 기초	증강은 새로운 환자를 만드는 것이 아니다	12
2. 의료 이미지 AI	전이학습: 일반 특징을 가져오는 출발점	13
2. 의료 이미지 AI	부분 미세조정: 무엇을 실제로 바꿨나	14
2. 의료 이미지 AI	미세조정 뒤 좋아진 이유와 말할 수 있는 범위	15
2. 의료 이미지 AI	B0·B1·224·256·384를 읽는 법	16
2. 의료 이미지 AI	CE: 무엇을 틀렸다고 계산할까	17
2. 의료 이미지 AI	Label Smoothing: 확신을 조금 완화하기	18
2. 의료 이미지 AI	Focal Loss: 어려운 표본에 더 집중하기	19
2. 의료 이미지 AI	Adam·학습률·BN·Dropout은 각각 무엇일까	20
2. 의료 이미지 AI	학습곡선·최고 모델·추가 학습 해석하기	21
2. 의료 이미지 AI	Accuracy·F1·혼동행렬을 함께 읽기	22
2. 의료 이미지 AI	Skin과 v1 실험에서 얻은 결론	23
2. 의료 이미지 AI	SupCon: 특징 공간에서 클래스를 분리하기	24
2. 의료 이미지 AI	DINOv2와 EfficientNetV2-S를 비교한 이유	25
2. 의료 이미지 AI	Hair B1·384와 SAM·앙상블의 후속 판단	26
2. 의료 이미지 AI	WS-DAN: 중요한 영역을 찾아 활용하기	27
2. 의료 이미지 AI	PMG: 작은 특징과 전체 구조를 함께 배우기	28
2. 의료 이미지 AI	PMG 코드와 Loss가 흔들리는 이유	29
2. 의료 이미지 AI	MixStyle과 MedSigLIP은 무엇이 다를까	30

목차 · 계속

제목 옆 숫자는 실제 PDF 페이지다. 본편의 출처 번호는 뒤의 논문·문서 목록과 연결된다.

2. 의료 이미지 AI	양호를 더한 Hair 6종은 새 과제다	31
2. 의료 이미지 AI	시간·크기·정확도와 최종 후보의 역할	32
3. 로봇팔	로봇팔 전체 흐름: 보기와 움직이기	33
3. 로봇팔	사진 라벨과 동작 시연 데이터	34
3. 로봇팔	YOLO는 약통의 위치를 찾는다	35
3. 로봇팔	로봇 VLM의 종류·자세·파지 판단	36
3. 로봇팔	카메라 좌표·마커·TCP와 보정	37
3. 로봇팔	ACT: 행동을 여러 시점 묶음으로 예측하기	38
3. 로봇팔	ACT Loss와 실제 파지 성공이 다른 이유	39
3. 로봇팔	Tracking Gate와 실제 움직임 확인	40
3. 로봇팔	로봇 결과와 아직 남은 평가	41
4. LLM과 VLM	LLM은 문장을 토큰으로 배우는 모델	42
4. LLM과 VLM	우리 설명 LLM과 독립 VLM의 두 경로	43
4. LLM과 VLM	프롬프트·RAG·SFT를 구분하기	44
4. LLM과 VLM	SFT 데이터와 답변 토큰 마스킹	45
4. LLM과 VLM	LoRA: 작은 추가 행렬을 학습하기	46
4. LLM과 VLM	QLoRA·양자화·메모리 이해하기	47
4. LLM과 VLM	VLM은 이미지 특징을 언어 모델과 연결한다	48
4. LLM과 VLM	팀원은 어디까지 실제 학습했나	49
4. LLM과 VLM	Forge 대시보드·MedVLM·GitHub의 역할	50
4. LLM과 VLM	설명 LLM 평가: 말을 잘하는 것 이상	51
4. LLM과 VLM	LLM 지연·처리량·컨텍스트 비용	52
5. 통합과 복습	분류 결과를 LLM에 어떻게 전달할까	53
5. 통합과 복습	한 가지 가설을 비교하는 실험 설계	54
5. 통합과 복습	발표할 때 방법을 설명하는 네 문장	55
5. 통합과 복습	스스로 답해 볼 핵심 질문	56

목차 · 계속

제목 옆 숫자는 실제 PDF 페이지다. 본편의 출처 번호는 뒤의 논문·문서 목록과 연결된다.

6. 원본 결과표	Hair v1: 여섯 기본 조건의 원본 값	57
6. 원본 결과표	Web Skin v1: 여섯 기본 조건의 원본 값	58
6. 원본 결과표	Hair 6종: 원본·증강과 두 모델 구성	59
6. 원본 결과표	보존한 선정 버전 7개와 정확한 평가값	60
6. 원본 결과표	실행 비용: 정확한 p50과 파일 크기	61
6. 원본 결과표	34개 저장·측정 조건: Skin 10종	62
6. 원본 결과표	34개 저장·측정 조건: Web Skin 5종	63
6. 원본 결과표	34개 저장·측정 조건: Hair 5종	64
6. 원본 결과표	34개 저장·측정 조건: Hair 6종	65
7. 용어와 근거	핵심 용어 사전 1	66
7. 용어와 근거	핵심 용어 사전 2	67
7. 용어와 근거	논문·공식 문서 1	68
7. 용어와 근거	논문·공식 문서 2	69
7. 용어와 근거	논문·공식 문서 3	70
7. 용어와 근거	논문·공식 문서 4	71
7. 용어와 근거	프로젝트 내부 근거와 상태 구분	72
7. 용어와 근거	현재 상태와 앞으로 공부를 이어갈 순서	73

어떤 순서로 공부하면 좋을까

내용을 모두 외우기보다 같은 질문을 여러 방법에 적용해 보는 것이 좋다.

차례	먼저 이해할 내용	설명할 수 있어야 하는 것
1. 공통 기초	데이터·학습·추론·평가	정답을 보는 사진과 성능을 확인하는 사진의 차이
2. 의료 AI	전이학습·미세조정·손실·논문 방법	특징, 출력층, 학습 신호 중 무엇이 바뀌는가
3. 로봇팔	인식·검출·좌표·ACT·제어	사진의 답과 실제 동작 성공이 왜 다른가
4. LLM/VLM	토큰·프롬프트·SFT·LoRA·평가	새 지시문과 새 가중치 학습의 차이
5. 통합과 복습	추론 계약·실행 비용·질문	각 결과를 무엇과 비교해야 하는가

추천 학습 순서

첫날에는 미세조정까지 읽고 "구조와 가중치는 다르다"를 설명해 본다. 다음에는 CE·LS·Focal과 Validation을 연결한다. 논문 방법은 최종 채택된 PMG와 B1·384, 이어 SupCon·SAM을 먼저 읽는다. 로봇은 YOLO와 ACT, LLM은 SFT와 LoRA를 중심으로 확장한다.

발표자료와 함께 읽기

발표 10~14쪽은 데이터·초기 모델, 23~35쪽은 정리와 v1, 36~45쪽은 논문 비교, 46~59쪽은 Hair6·실행 비용·최종 평가다. 로봇은 15~18·60~66쪽이다. 화면에 적힌 쪽수 일부가 어긋나므로 실제 파일의 슬라이드 순서를 사용한다.

이해 확인

질문: 논문 이름을 아는 것과 방법을 이해하는 것의 차이는?

답의 핵심: 어느 데이터·모델 부분을 바꿨는지와 비교 결과를 설명할 수 있으면 이해한 것이다.

근거: 내부 D01, D02, D07

네 가지 AI 과제부터 구분하기

같은 사진을 사용해도 모델에 시키는 일과 정답 형식이 다르면 다른 과제다.

과제	입력과 출력	프로젝트 사례
분류	사진 → 허용된 클래스 점수	Skin·Web Skin·Hair
검출	사진 → 물체 위치 상자와 클래스	약통 YOLO
생성·문답	질문·문맥·사진 → 문장 또는 구조화 답	설명 LLM·독립 VLM
행동 정책	현재 영상·관절 상태 → 다음 행동	로봇팔 ACT

분류와 검출

분류는 사진 전체가 어느 범주에 속하는지를 답한다. 검출은 물체가 어디 있는지도 답한다. 약통 상자를 잘 그려도 A·B·C 종류 구분용 라벨이 없으면 종류를 판별한 것은 아니다. 피부 분류기를 YOLO로 바꾸는 것은 출력층만 교체하는 정도가 아니라 문제와 데이터 라벨 자체를 바꾸는 일이다.

문장과 행동

VLM이 "왼쪽 약통을 잡아라"라고 말하는 것만으로 로봇이 그 위치에 정확히 도달하지 않는다. 좌표 변환과 동작 정책·제어가 필요하다. 분류기가 질환 후보를 출력한 것과 LLM이 그 결과를 쉬운 문장으로 설명한 것도 서로 다른 성과다.

이해 확인

질문: 약통 YOLO mAP가 높으면 바구니 투입 성공률도 높은가?

답의 핵심: 아니다. 위치 검출 이후 좌표·접근·파지·이동·놓기 각각의 실패가 남을 수 있다.

근거: 내부 D07. 외부 R14, R15

세 도메인과 클래스의 정확한 의미

표의 순서는 저장 모델의 클래스 배열이다. 출력 숫자의 인덱스도 이 순서를 따른다.

과제	저장 클래스 순서
Skin 10종	광선각화증, 기저세포암, 보웬병, 사마귀, 지루각화증, 편평세포암, 표피낭종, 피부섬유종, 혈관종, 흑색점
Web Skin 5종	건선, 아토피, 여드름, 정상, 주사
Hair 6종	모낭사이홍반, 미세각질, 비듬, 탈모, 피지과다, 양호

촬영 목표와 원천 자료

Web Skin은 얼굴 사진, Skin은 확대 피부, Hair는 확대 두피에 적용하려는 별도 과제다. 공개 원천의 촬영 조건과 실제 목표 장비의 사진 분포가 완전히 같다고 검증한 것은 아니다. 이 차이를 Domain Gap이라고 한다.

초기 방향의 변경

초기에는 병변 검출 후 crop한 사진을 분류하는 방향도 검토했다. 하지만 넓게 퍼진 변화와 여러 병변, 위치 라벨의 어려움 때문에 현재 전문 분류 과제와 별도로 정리했다. 원천에서 사람이 보기에 비슷한 범주를 제외한 판단과 임상적으로 그 범주가 같다는 주장은 다르다.

이해 확인

질문: 배열 순서를 가나다순으로 다시 정렬해도 되는가?

답의 핵심: 안 된다. 모델의 출력 번호와 라벨의 관계가 바뀔 수 있다.

근거: class_names.json 원문. PROJECT_BACKGROUND, 최종 종합 보고서

학습은 숫자를 바꾸고 추론은 답을 낸다

모델은 구조와 그 구조 안에 저장된 가중치로 이뤄진다.

학습의 한 번

사진과 정답을 넣어 예측하고, 정답과 얼마나 다른지 손실을 계산한다. 손실을 줄이는 방향으로 학습 가능한 가중치를 갱신한다. 이 과정이 반복되면서 같은 입력에서 다른 출력을 내게 된다. 모델 구조가 같아도 가중치가 달라지면 서로 다른 학습 모델이다.

추론의 한 번

저장 모델에 새 입력을 넣어 결과를 계산한다. 보통 정답이나 손실 계산, 가중치 갱신은 필요 없다. 학습 때 쓴 증강·Dropout·대조학습 과정이 추론에도 전부 반복되는 것은 아니다. 실제 추론 경로에 남아 있는 연산을 확인해야 한다.

용어	쉬운 뜻	혼동하기 쉬운 점
가중치	모델이 학습한 숫자	코드 파일이나 데이터 사진 자체가 아님
체크포인트	학습 도중 저장한 상태	마지막 저장본이 항상 최고는 아님
epoch	Train을 한 차례 사용하는 단위	사진 수가 다르면 계산량도 달라짐
batch	한 갱신에 묶어 처리하는 표본	batch와 전체 Train 수는 다름
step/update	가중치를 갱신하는 횟수	로봇 제어 한 동작과 같은 단위가 아님

이해 확인

질문: 학습 15회가 같은 두 실험은 계산량도 같은가?

답의 핵심: Train 장수와 배치, 한 배치의 내부 갱신 횟수에 따라 다르다. PMG는 한 배치에서도 여러 갱신을 한다.

근거: 실제 코드: common_engine.py, web_skin_paper_suite.py

전이·미세조정·모방·강화학습 구분하기

"논문 기반 모델 강화"라는 프로젝트 표현이 강화학습 알고리즘을 썼다는 뜻은 아니다.

용어	배우는 대상·방식	이번 프로젝트
사전학습	큰 원천 자료에서 먼저 특징·언어 학습	ImageNet·DINOv2·MedSigLIP·LLM 기반 모델
전이학습	기존 학습 결과를 새 과제에 활용	새 질환 분류층
미세조정	기존 가중치 일부·전체를 새 자료로 조정	부분 EfficientNet 적응
모방학습	사람 시연의 관측·행동을 따라 학습	로봇 ACT
강화학습	행동의 보상으로 정책을 개선	현재 보고된 핵심 실험과 별개

같은 학습이라는 말 안의 차이

CE 분류는 클래스 정답, SFT는 정답 응답, ACT는 시연 행동을 배운다. 실제 환경에서 보상을 받아 정책을 갱신하는 강화학습을 이 기록만으로 수행했다고 소개하지 않는다.

새로운 모델의 뜻

새 구조를 발명하지 않아도 우리 데이터로 가중치를 학습하면 별도 체크포인트가 만들어진다. 사전학습 모델을 우리 과제에 적응시킨 성과와 새로운 알고리즘의 기여를 구분해 발표하면 된다.

이해 확인

질문: 논문 방법을 추가했으니 강화학습인가?

답의 핵심: 아니다. 분류 손실·대조학습·전이학습·최적화 등 실제 학습 목적을 말해야 한다.

근거: 내부 D01~D03, R15

데이터 버전과 분할을 먼저 읽기

성능 숫자를 이해하려면 어떤 사진에서 얻은 결과인지부터 알아야 한다.

과제	초기 원본	정리 후 원본 Train / Val / Test	증강 포함 Train
Skin 10종	9,000	7,249 / 1,000 / 700	14,498
Web Skin 5종	4,500	3,600 / 500 / 400	7,200
Hair 5종	14,500	10,032 / 1,252 / 1,252	15,047
Hair 6종	별도 확장	10,460 / 1,305 / 1,305	17,615

Train·Validation·Test

Train은 정답을 보며 배우는 사진이다. Validation은 학습 설정과 저장 시점을 선택하는 사진이다. Test는 후보 고정 뒤 확인하는 사진이다. Validation에서 여러 설정을 고르는 것은 가능하지만 같은 Test 점수를 계속 보고 설정을 바꾸면 Test도 사실상 개발용이 된다.

원천과 프로젝트 선별본

Skin과 Web Skin은 AI Hub 합성 데이터 원천의 일부를 프로젝트 클래스와 용도에 맞게 선별했다. Hair도 원천 전체가 아니라 선별본을 사용했다. "원본 Train"은 추가 증강 전이라는 뜻이지 모든 사진이 우리가 실제 장비로 촬영한 원본이라는 뜻은 아니다.

평가 집합이 바뀐 비교

Skin·Hair는 정리 과정에서 평가 구성도 바뀌었다. 초기→v1의 기록 차이를 미세조정 한 가지의 순수 효과로 읽지 않는다. 같은 분할 안의 비교를 별도로 보는 이유다.

근거: 내부 D01~D03. 원천 출처 R20~R22

중복 검사와 데이터 누수

모델이 학습 때 본 사진을 평가에서 다시 만나면 새 사진을 구분하는 능력을 과대평가할 수 있다.

검사 수준의 차이

파일 SHA-256은 바이트가 같은지 확인한다. RGB 픽셀 해시는 저장 형식 차이를 넘어 디코딩된 픽셀이 같은지 확인한다. 비슷한 각도·조명·연속 촬영은 이 두 검사로 모두 잡히지 않는다. 사람·병변·세션 그룹을 확인하는 것이 별도로 필요하다.

확인한 기록	값	올바른 해석
Hair Train-Val 동일 파일	195건	분할 쌍별 겹침
Hair Train-Test 동일 파일	178건	삭제 장수와 다름
Hair Val-Test 동일 파일	16건	세 분할 공통이면 중복 집계 가능
Skin 완전 동일 정리	51장	특정 검사로 확인한 정리 범위
새 Hair 양호와 기존 원본	파일·RGB 완전 일치 0장	사람·세션이 독립이라는 증명은 아님

LLM·VLM에서도 같은 문제

같은 사진의 질문만 바꾼 문답, 한 문서의 비슷한 문장, 증강 파생본이 Train과 Test에 갈라져도 누수가 생긴다. 행 수만 섞는 분할보다 원본 이미지·문서·사람 그룹을 묶는 분할이 중요하다.

이해 확인

질문: 파일 이름이 다르면 중복이 아닌가?

답의 핵심: 아니다. 다른 이름의 동일 사진도 있고, 같은 이름의 다른 사진도 있을 수 있다.

근거: 내부 D02, D03. hair_good_cross_audit 검토 기록

증강은 새로운 환자를 만드는 것이 아니다

사진의 라벨을 유지한 채 촬영 조건의 변화를 연습시키려는 방법이다.

왜 사용했나

실제 촬영에서는 밝기·색감·회전·초점이 달라진다. 한 조건에만 맞추지 않게 변형한 Train을 추가했다. 너무 강한 변형은 병변의 색·미세 질감을 훼손할 수 있어 항상 성능이 좋아지는 것은 아니다.

Hair 코드의 예	설정	의미
미세 회전	확률 0.65, -8~8도	작은 촬영 기울기
밝기	확률 0.75, 배율 0.82~1.18	조도 변화
대비	확률 0.65, 배율 0.85~1.15	명암 변화
색·blur·noise	일부 사진에 약하게 적용	색감·초점·센서 변화
crop·확대	확률 0.30, 비율 0.92~1.0	약한 구도 변화

코드와 당시 데이터의 구분

위 값은 scripts/preprocess_hair.py에 현재 보존된 함수 설정이다. 모든 과거 ZIP에 이 함수가 같은 버전으로 적용됐다고 자동으로 소급하지 않는다. 실제 실험에는 그 ZIP의 manifest·변환 기록·코드 버전을 함께 봐야 한다.

실험의 함정

증강 포함 Train은 사진 수가 늘어 같은 15 epoch라도 갱신 횟수가 많을 수 있다. 효과에는 변형 다양성과 계산량 차이가 함께 포함된다. Val/Test에는 원본을 사용하고, 증강본은 원본과 같은 분할을 상속한다.

근거: scripts/preprocess_hair.py, preprocess_skin.py, preprocess_web_skin.py. 내부 D02

전이학습: 일반 특징을 가져오는 출발점

EfficientNet 구조를 가져오는 것과 이미 학습된 가중치를 가져오는 것은 함께 설정할 수 있지만 다른 개념이다.

원래 무엇을 배웠나

ImageNet은 동물·사물 등 일반 이미지 범주로 구성된 데이터다. 여기서 배운 모서리·패턴·질감은 새로운 이미지 과제의 출발점으로 활용할 수 있다. 원래 모델이 우리 질환 이름까지 이미 배웠다는 뜻은 아니다.

```
base = keras.applications.EfficientNetB0(
    weights="imagenet", include_top=False,
    input_shape=(224, 224, 3))
base.trainable = False
# 특징 위에 우리 클래스 수의 Dense 층을 붙임
```

실제로 불러오는 것

Keras는 모델을 만들고 학습하는 도구다. weights="imagenet"은 사전학습 가중치를 선택하고 include_top=False는 기존 ImageNet 분류층을 제외한다. 우리 클래스 수의 새 분류층이 기존 특징과 질환 라벨의 관계를 학습한다.

초기 모델도 우리 모델이다

분류층만 학습해도 우리 과제용 모델이 만들어진다. 이후 미세조정은 그 모델을 우리 사진에 더 적응시키는 다음 단계다. 새 알고리즘 구조를 발명한 것과 구분한다.

이해 확인

질문: import keras를 하면 우리 피부 모델이 내려받아지는가?

답의 핵심: 아니다. 라이브러리 로드, 사전학습 모델 생성, 우리 저장 모델 로드는 서로 다르다.

근거: R01, R02. common_engine.py:build_model

부분 미세조정: 무엇을 실제로 바꿨나

가장 중요한 변화는 추가 횟수보다 특징 추출부 일부도 학습하도록 허용한 것이다.

항목	Stage 1	Stage 2
특징 추출부	고정	후반부 일부 학습
새 분류층	학습	계속 학습
Adam 학습률	0.0001	0.00001
대표 Clean 학습량	15 epoch	10 epoch
Batch Normalization	추론 모드	고정 유지

실제 범위

본체의 마지막 30개 레이어 범위 중 BatchNormalization이 아닌 층을 학습 가능하게 바꿨다. 따라서 정확히 30개 모두가 갱신된다는 뜻은 아니다. trainable 설정을 바꾸고 compile을 다시 호출해 학습 대상과 optimizer를 반영한다.

왜 단계로 나눴나

초기 새 분류층은 무작위 숫자에서 시작한다. 이때 본체를 함께 크게 바꾸면 이미 배운 특징을 훼손할 수 있다. 먼저 분류층을 적응시키고, 그다음 낮은 학습률로 일부 특징을 천천히 바꾼다. 미세조정도 과적합할 수 있어 Validation을 확인해야 한다.

발표에서는 이렇게

일반 이미지에서 배운 특징을 고정해 사용하던 방식에서, 특징 추출부 후반부도 우리 피부·두피 데이터에 적응시키는 방식으로 바꿨습니다.

근거: R02. common_engine.py:configure_partial

미세조정 뒤 좋아진 이유와 말할 수 있는 범위

가장 그럴듯한 설명은 기존 고정 특징의 한계가 줄었다는 것이다. 실제 원인을 하나로 확정한 실험과는 구분한다.

가능한 변화

일반 특징만으로 비듬과 미세각질이 비슷하게 표현됐다면 마지막 분류층만 조정하는 데 한계가 있다. 특징 추출부도 조정하면 미세 질감과 모낭 주변 변화 같은 구분 단서를 다르게 표현할 기회가 생긴다. 어떤 특징이 실제로 개선됐는지는 별도 분석 없이 단정하지 않는다.

변경 종류	함께 있었던 일	해석
학습 범위	부분 해제 + 학습률 감소 + 추가 epoch	Stage 2 조합의 효과
초기 → v1	데이터 정리·입력·Loss·본체 변화	전체 과정의 기록 차이
같은 분할의 조건 비교	한 조건 또는 명시된 동반 변경	그 비교의 제한된 근거

순수 미세조정 효과를 더 엄격히 보려면

같은 데이터·초기 가중치·입력·Loss를 유지하고 분류층만 추가 학습하는 조건과 부분 미세조정 조건을 비교해야 한다. 갱신 수와 저장 기준도 맞추면 해석이 더 명확하다. 이것은 비교 설계 설명이며 새로 실행한 결과가 아니다.

발표에서는 이렇게

미세조정을 시작으로 여러 학습 조건을 개선하며 검증 성능이 높아졌습니다. 상승폭 전체를 미세조정 하나의 효과라고 분리해 주장하지는 않습니다.

이해 확인

질문: 미세조정하면 새로운 구조가 생기는가?

답의 핵심: 주로 기존 구조의 일부 가중치가 달라진다. 프로젝트에서는 처음 분류층을 우리 클래스 수로 바꾼 일도 별도로 있었다.

근거: 내부 D01~D03. R02

B0·B1·224·256·384를 읽는 법

모델 이름, 입력 크기, 선정 버전은 각각 다른 정보다.

EfficientNet의 아이디어

원논문은 깊이·너비·해상도를 균형 있게 확장하는 방식을 제안한다. B0와 B1은 계열 내 구조 구성이다. 프로젝트의 v1·v2는 후보 선정 버전명이며 EfficientNetV2라는 다른 모델 계열과도 다르다.

큰 입력을 시험한 이유

각질이나 작은 병변이 사진을 줄이는 과정에서 충분히 표현되지 않을 가능성을 봤다. 입력을 키워도 원래 없는 정보를 복원하는 것은 아니고 계산량·메모리·지연은 늘 수 있다. 가장 큰 입력을 항상 선택하는 이유가 되지 않는다.

실험	고정·변경	결과 해석
Hair B0 224 ↔ 256	B0·CE 유지, 입력 변경	같은 분할의 입력 비교
Hair v1 ↔ v2	학습 경로 등 차이 포함	384 하나의 효과로 단정 금지
Web PMG B0·256 ↔ B1·384	본체·입력·batch 32→16	규모 조합 비교

사용할 때도 크기를 맞춰야 한다

B1·384로 저장한 모델은 해당 전처리를 적용한다. 사용자가 촬영하는 원본 사진을 반드시 384 해상도로 저장해야 한다는 뜻은 아니다. 원본 RGB를 모델 입력 크기로 변환하는 경로가 필요하다.

근거: R01. 내부 D03, PMG 규모 비교 기록

CE: 무엇을 틀렸다고 계산할까

Loss는 학습 신호이고 Accuracy는 평가 요약이다. 둘은 같은 숫자가 아니다.

기본 원리

Cross Entropy는 정답 클래스에 준 점수가 작을수록 큰 손실을 준다. 설명용 가상 예로 정답이 비듬일 때 비듬 점수 0.9보다 0.2를 준 예측에 더 큰 손실을 준다. 다중 분류에서 정답 one-hot에 대해 기본식은 -log(p_true)다.

```
loss = keras.losses.CategoricalCrossentropy()
model.compile(optimizer=Adam(1e-4),
              loss=loss, metrics=["accuracy"])
```

logits와 softmax

logits는 softmax 전의 점수다. softmax는 클래스 점수를 합이 1인 형태로 바꾼다. PMG는 각 분기의 logits를 다루므로 from_logits=True로 CE를 계산한다. 이미 softmax한 값에 다시 logits용 처리를 하면 계산이 달라진다.

왜 최종 모델에도 CE가 남았나

CE는 출발 기준이지만 반드시 더 고급 Loss로 교체해야 하는 것은 아니다. Skin v1, Web Skin v1과 PMG v2에 CE가 남았다. 우리 데이터에서 실제로 유리한지를 Validation으로 판단했다.

이해 확인

질문: softmax 0.9면 실제 정답 확률이 90%인가?

답의 핵심: 그렇게 검증된 보정 결과가 없다면 모델 출력 점수다. 실제 정답 빈도와 일치하는지는 별도 calibration 평가가 필요하다.

근거: common_engine.py:loss_function, web_skin_paper_suite.py

Label Smoothing: 확신을 조금 완화하기

라벨을 버리는 것이 아니라 학습 목표 분포를 부드럽게 바꾼다.

어떻게 바뀌나

one-hot은 정답 1, 나머지 0이다. Keras smoothing 0.05는 K개 클래스에서 정답을 1-0.05+0.05/K, 나머지를 0.05/K로 바꾼다. 5종의 설명용 목표는 정답 0.96, 나머지 각 0.01이다.

```
loss = keras.losses.CategoricalCrossentropy(
    label_smoothing=0.05)
```

왜 우리에게 시험했나

두피처럼 클래스 경계가 시각적으로 모호한 경우 정답을 과도하게 확신하는 방향을 완화하면 도움이 될 수 있다는 가설이었다. 틀린 라벨을 자동으로 찾아 수정하는 방법도, 클래스 수를 늘리는 방법도 아니다.

관측 결과

Hair B0·256의 CE와 LS를 같은 Validation에서 비교했고 LS가 v1 후보 선별에 유리했다. Web Skin에서는 CE보다 앞서지 않았다. Hair 최종 B1·384에도 LS 0.05를 사용했다. 모든 과제에서 항상 좋은 방법이라는 결론은 아니다.

발표에서는 이렇게

과도한 확신을 줄일 가능성을 검토하기 위해 정답 목표를 조금 부드럽게 학습했습니다.

이해 확인

질문: LS를 쓰면 점수가 곧 잘 보정된 확률이 되는가?

답의 핵심: 아니다. 학습 규제와 점수 보정 검증은 별개다.

근거: R03. common_engine.py:loss_function

Focal Loss: 어려운 표본에 더 집중하기

모든 사진의 손실 기여를 같은 방식으로 취급하지 않는 방법이다.

기본 원리

원논문은 쉬운 배경 표본이 많은 물체 검출 문제를 다룬다. 핵심은 잘 맞힌 표본의 CE 기여를 (1-p_true)^gamma 같은 항으로 낮추는 것이다. gamma가 커질수록 쉬운 표본의 상대 기여가 더 줄어든다.

```
loss = keras.losses.CategoricalFocalCrossentropy(
    alpha=1.0, gamma=1.5)
```

우리의 가설

프로젝트는 균형화한 클래스도 있어 원논문의 전경·배경 불균형과 같지 않다. 그 대신 시각적으로 어려운 유사 클래스 예에 집중하는 원리가 유리할지를 시험했다. gamma는 모델 크기나 새 클래스 수가 아니다.

관측과 선택

Hair·Web Skin v1 Validation에서 Focal이 최종 선택을 바꿀 만큼 앞서지 않았다. Hair 초기 묶음에서 Focal의 Test가 높았더라도 Test를 보고 후보를 다시 바꾸는 이유로 사용하지 않았다. 설정 선택과 최종 확인의 역할을 지켰다.

이해 확인

질문: Focal loss 값이 CE보다 작으면 무조건 좋은가?

답의 핵심: 아니다. 손실 정의가 달라 절댓값을 그대로 비교할 수 없다. 같은 평가 지표를 사용해야 한다.

근거: R04. 내부 D02, D03

Adam·학습률·BN·Dropout은 각각 무엇일까

이름이 많아도 구조, 학습 범위, 갱신 방식, 규제로 나누면 이해하기 쉽다.

항목	하는 일	우리 코드에서
Adam	기울기를 이용해 가중치 갱신	Stage 1 1e-4, Stage 2 1e-5
학습률	갱신 크기의 기준	작으면 조심스럽지만 느릴 수 있음
Batch Normalization	중간 특징 통계를 조정	부분 미세조정에서도 고정
Dropout	학습 중 일부 특징을 끔	공통 분류 head에서 0.3
클래스 가중치	클래스 손실 기여 조정	Hair6 학습 표본 수에 따라 사용

trainable과 training=False

trainable=False는 가중치를 갱신하지 않게 한다. training=False는 BN·Dropout 같은 층의 동작 모드를 정한다. 둘은 같은 명령이 아니다. 공통 코드는 본체를 training=False로 호출하면서 허용한 일부 가중치에는 기울기가 흐를 수 있다.

재컴파일하는 이유

학습 가능한 층을 바꿨다면 학습 함수가 새 변수 목록을 사용하도록 구성해야 한다. optimizer 상태도 기록해야 중단 후 재개와 단순 가중치 이어 학습을 구분할 수 있다.

이해 확인

질문: 학습률을 낮추면 반드시 더 정확해지는가?

답의 핵심: 아니다. 학습 속도와 최적화 경로가 바뀌며 너무 낮으면 충분히 적응하지 못한다.

근거: common_engine.py. 내부 D02, Hair6 실험 기록

학습곡선·최고 모델·추가 학습 해석하기

곡선은 학습 과정이고 최종 후보는 저장된 특정 체크포인트다.

네 선 읽기

Train Accuracy가 오르고 Loss가 내려가면 학습 데이터에 더 맞아간다. Validation이 함께 개선되는지 확인한다. Train만 계속 좋아지고 Validation이 정체·악화되면 일반화 차이가 커질 수 있다. 단순한 흔들림 한 번만으로 과적합 원인을 확정하지 않는다.

파일·표현	뜻	선택 주의
stage1_best	1단계 선택 기준 최고 저장	2단계 시작점으로 재사용 가능
stage2_best	2단계 선택 기준 최고 저장	마지막 epoch와 다를 수 있음
last	마지막 상태	최고 상태를 보장하지 않음
+5 epoch	기존 모델 후속 학습	부모 최고 미달이면 부모 유지 가능

실제 사례

Hair v1은 B1·256 미세조정에 5회를 더한 조건이 선택됐다. Web Skin의 B1 연장은 부모 최고를 넘지 못해 기존 최고를 유지했다. PMG B1·384는 마지막보다 앞선 epoch의 Validation이 높아 최고 체크포인트를 사용했다.

PMG는 Loss 정의가 다르다

Train loss는 여러 분기 손실을 더하고 결합 손실에 가중치를 주지만 Validation loss는 결합 분기의 CE다. 두 선 높이의 차이를 같은 손실을 계산한 일반 그래프처럼 해석하면 안 된다.

근거: 내부 D03. web_skin_paper_suite.py:_fit_pmg_stage

Accuracy·F1·혼동행렬을 함께 읽기

전체 정답 수만으로는 어느 클래스에서 무엇을 놓쳤는지 알 수 없다.

세 가지 비율

Precision은 해당 클래스로 예측한 것 중 맞은 비율이다. Recall은 실제 그 클래스 중 찾아낸 비율이다. F1은 Precision과 Recall의 조화평균이다. Macro F1은 클래스별 F1을 같은 비중으로 평균한다. Accuracy와 같을 필요가 없다.

```
precision = TP / (TP + FP)
recall    = TP / (TP + FN)
F1        = 2 * precision * recall / (precision + recall)
accuracy  = 전체 정답 수 / 전체 사진 수
```

설명용 가상 예

비듬 사진 중 상당수를 미세각질로 보내면 비듬 Recall이 낮아진다. 다른 증상 사진까지 비듬이라고 자주 부르면 비듬 Precision이 낮아진다. 같은 Accuracy라도 어떤 오류가 생겼는지는 다를 수 있다.

혼동행렬

한 축은 실제 라벨, 다른 축은 예측 라벨이다. 축 방향은 그림마다 확인한다. 대각선은 정답이며 대각선 밖은 혼동이다. Hair에서는 미세각질과 비듬 사이의 양방향 혼동을 따로 확인했다.

이해 확인

질문: 양호 클래스의 F1이 높으면 6종 전체도 모두 잘되는가?

답의 핵심: 아니다. 클래스별 성능을 함께 봐야 하고 다른 질환의 낮은 Recall을 평균이 가릴 수도 있다.

근거: classification_metrics 구현. 내부 D03

Skin과 v1 실험에서 얻은 결론

기본 학습을 정리하고 다음 연구의 출발 모델을 고른 단계다.

과제	선정된 v1	선정 이유
Skin	B0·224·CE·원본+증강	Clean 같은 Validation에서 원본보다 높음
Web Skin	B0·256·CE	Accuracy 동률이면 앞선 조건 유지
Hair5	B1·256·LS 0.05·추가 5회	저장 Validation Accuracy 선두

Skin 결과

Clean 원본 Validation Accuracy는 0.973, 증강 조건은 0.982였다. 증강 모델의 Macro F1은 0.9820008885656606이다. 고정 후보의 Test Accuracy는 0.9871428571428571이다. 초기의 매우 높은 점수를 그대로 확정하지 않고 데이터 검사 후 후보를 고른 점이 중요하다.

Web Skin과 Hair의 해석

Web Skin에서는 B1의 F1이 약간 높아도 당시 Accuracy 우선 동률 규칙으로 B0를 선택했다. Hair에서는 당시 Validation F1이 저장되지 않은 여섯 조건을 Accuracy로 비교했다. 저장되지 않은 Val F1 대신 Test F1을 넣지 않았다.

발표에서는 이렇게

기본 학습 비교로 v1 기준을 만든 뒤, 남은 클래스 혼동을 해결할 수 있는 방법을 다음 단계에서 시험했습니다.

근거: 내부 D02, D03. 선정 메타데이터와 별첨 34개 표

SupCon: 특징 공간에서 클래스를 분리하기

정답 분류만 잘하게 하는 것에서 한 걸음 더 나아가 특징 간 관계를 학습한다.

핵심 원리

같은 클래스 표본의 특징은 가까워지고 다른 클래스는 멀어지도록 손실을 구성한다. 두피의 비슷한 질감이 겹쳐 표현되는 문제에 도움이 될 수 있다는 가설이었다. 프로젝트는 대조 표현 학습 뒤 분류기를 학습하는 경로를 사용했다.

코드에서 달라진 부분

단순 model.compile(loss=CE)만 바꾼 것은 아니다. 특징을 만드는 encoder와 projection head, 같은 라벨의 짝 관계, 별도 대조 손실과 학습 단계가 필요하다. 추론에서는 최종 분류 경로를 사용하므로 학습의 모든 짝 비교를 반복할 필요는 없다.

같은 Hair Validation	기준선	SupCon
정답 수	971 / 1,252	991 / 1,252
Accuracy	0.7755591054313099	0.7915335463258786
Macro F1	0.7746028470442391	0.7910880666407202
미세각질↔비듬 혼동	74건	69건

선정 해석

이 비교에서는 효과를 얻었지만 최종 B1·384 Adam이 더 높은 전체 검증 성능을 보였다. 최종 Hair가 SupCon 모델이라고 소개하지 않는다. 효과가 없었던 실험이 아니라 유용했으나 최종 후보를 이기지 못한 실험이다.

이해 확인

질문: SupCon은 class 수를 늘리는 방법인가?

답의 핵심: 아니다. 주어진 라벨들의 특징 표현을 학습하는 방법이다.

근거: R05. paper_suite.py, HAIR_SUPCON_RESULT_20260917.md

DINOv2와 EfficientNetV2-S를 비교한 이유

특징을 배우는 출발점이나 CNN 구조 자체를 바꿔 보는 후보 탐색이었다.

DINOv2

라벨 없이 사전학습한 범용 시각 특징을 활용한다. 우리 실험은 Small 인코더를 고정하고 224 입력의 새 선형 분류층만 15회 학습했다. 우리가 대규모 자기지도 사전학습을 수행한 것은 아니다. 결과는 현재 고정 특징의 활용 가능성에 관한 것이다.

EfficientNetV2-S

학습·파라미터 효율을 고려한 다른 CNN 계열의 전이 가능성을 봤다. V2-S 구조를 256 입력 후보로 사용했다. 원논문의 모든 학습 정책·데이터를 똑같이 재현한 것은 아니다.

후보	Validation Accuracy	Validation Macro F1
DINOv2 Small·224	0.7699680511182109	0.7705341251195019
EfficientNetV2-S·256	0.7691693290734825	0.7681559382466019

무엇을 배웠나

새롭거나 범용성이 강한 사전학습 모델도 현재 데이터·전처리·학습 범위에서 자동으로 우수하지 않았다. DINOv2의 본체를 미세조정했을 때나 다른 입력의 결과까지 부정하는 실험은 아니다. 선별 실험의 학습 예산도 모두 같지 않았다.

이해 확인

질문: DINOv2가 낮았으니 Transformer가 두피에 부적합한가?

답의 핵심: 그렇게 일반화할 수 없다. 이번 고정 인코더·224·선형층 설정의 결과다.

근거: R06, R07. HAIR_REMAINING_METHODS_RESULT_20260917.md

Hair B1·384와 SAM·앙상블의 후속 판단

유망한 단일 모델을 찾은 뒤 복잡한 후속 방법이 더 나은지 확인했다.

B1·384 Adam

작은 각질·모낭 특징을 더 큰 입력으로 학습할 가능성을 확인했다. 최종 선택은 B1·384·LS 0.05·Adam이다. v1과 학습 경로까지 완전히 같지 않아 개선을 해상도 하나의 인과 효과로 분리하지 않는다.

SAM

파라미터 한 점뿐 아니라 주변에서도 손실이 낮은 방향을 찾는다. 학습 시 가중치 교란과 추가 기울기 계산이 들어간다. 같은 B1·384에서 Adam과 비교했고 일부 혼동은 줄었지만 전체 F1 개선은 없었다. 추론 때 교란 학습을 다시 하는 것은 아니다.

단순 확률 평균 앙상블

SupCon과 B1·384의 같은 사진 예측을 1:1 평균했다. 새 모델 학습이 아니라 두 저장 모델의 결합 평가다. 오답 보완 가능성이 있어도 단순 평균이 최종 단일 모델을 이긴다는 보장은 없다.

조건	Validation Accuracy	Validation Macro F1
B1·384 Adam	0.7963258785942492	0.7957146810115047
B1·384 SAM	0.7963258785942492	0.7954748920799393
1:1 확률 평균	0.7947284345047924	0.7942285283566071

이해 확인

질문: 최종 Hair에는 SupCon·SAM·앙상블이 모두 들어갔나?

답의 핵심: 아니다. 비교 뒤 B1·384 Adam 단일 모델을 선택했다.

근거: R08. 내부 D03, HAIR_SAM_RESULT, HAIR_CANDIDATE_COMPLEMENTARITY

WS-DAN: 중요한 영역을 찾아 활용하기

사진 전체에서 병변 단서가 작을 때 attention이 도움이 될지 시험했다.

원논문의 아이디어

구분에 유용한 영역을 attention map으로 표현하고 확대·가림 등을 학습에 활용한다. 별도 세부 위치 라벨이 없어도 분류에 유용한 부분을 학습하려는 방법이다. 원논문은 세밀 분류 문제를 다뤘다.

프로젝트 적용

Web Skin B0·256에 attention 기반 구조와 영역 처리를 응용했다. 얼굴 전체와 attention 확대 영역의 예측을 함께 활용하므로 내부 추론 경로가 기본 모델보다 복잡할 수 있다. 사용자가 사진을 두 번 촬영해야 하는 것은 아니다.

관측 결과

Validation Accuracy 0.764, Macro F1 0.7546949301321499로 기준선 B0·256·CE보다 낮았다. 중요한 부위를 잘 못 봤을 가능성은 분석 가설이며 attention 지도를 검증하지 않고 원인으로 확정할 수 없다.

발표에서는 이렇게

국소 병변을 자동으로 찾는 접근을 적용했지만, 현재 attention 설정은 우리 얼굴 피부 데이터에서 유리하지 않았습니다.

이해 확인

질문: attention 색 지도가 곧 병변 정답 위치인가?

답의 핵심: 아니다. 모델 내부 강조 정도이며 임상적 위치 라벨과의 일치 검증이 필요하다.

근거: R09. web_skin_wsdan.py, WEB_SKIN_PAPER_METHOD_RESULT

PMG: 작은 특징과 전체 구조를 함께 배우기

Progressive Multi-Granularity는 여러 크기의 특징을 단계적으로 학습한다는 뜻이다.

왜 얼굴 사진에 적용했나

작은 피부 질감은 중요하지만 얼굴 전체의 분포도 유용할 수 있다. 조각을 섞어 학습하면 전체 배치만 외우기보다 국소 특징을 보게 할 가능성이 있다. 여러 크기의 특징을 결합해 최종 분류한다.

학습 경로	프로젝트 구성	역할
작은 조각	8×8 jigsaw	세밀한 특징 경로 학습
중간 조각	4×4 jigsaw	다른 크기의 특징 학습
큰 조각	2×2 jigsaw	큰 영역 특징 학습
원본·결합	분기 특징을 결합한 출력	전체 정보의 종합

추론은 한 장

원본 한 장에서 세 분기 logits와 결합 logits를 합쳐 softmax한다. 학습할 때처럼 사용자가 조각난 사진을 준비하는 것은 아니다. 네 출력이 있으므로 일반 단일 softmax 모델처럼 첫 출력만 읽으면 계약이 달라진다.

결과

B0·256은 Validation Accuracy 0.85와 Macro F1 0.8473279632397033을 얻었다. 기준선 오분류는 102/500에서 75/500으로 줄었다. PMG B1·384는 더 높았지만 실행 비용을 고려해 B0가 전달 후보로 남았다.

이해 확인

질문: PMG는 WS-DAN과 MixStyle을 합친 방법인가?

답의 핵심: 아니다. 세 방법은 별도 실험 조건이다.

근거: R10. web_skin_paper_suite.py

PMG 코드와 Loss가 흔들리는 이유

기본 model.fit과 다른 내부 학습 경로를 이해하면 곡선이 덜 혼란스럽다.

```
# 동작 설명용 축약 코드
for images, labels in train:
    train_branch(jigsaw(images, 8), branch=0)
    train_branch(jigsaw(images, 4), branch=1)
    train_branch(jigsaw(images, 2), branch=2)
    train_fusion(images)
# 추론: softmax(sum(model(original_image)))
```

한 batch의 여러 갱신

각 분기와 결합 경로를 순서대로 갱신하므로 기본 분류기보다 학습 계산이 많다. 같은 epoch 수라는 이유만으로 동일 학습 예산이라고 볼 수 없다. 실제 코드는 GradientTape로 손실과 기울기를 계산한다.

Train/Validation Loss 정의

현재 Train loss는 세 분기 CE에 가중한 결합 CE를 더한다. Validation loss는 원본에서 결합 분기 CE를 계산한다. 서로 다른 목적의 숫자라 Train이 더 높다는 것만으로 이상이 아니다. Accuracy도 어떤 출력으로 계산했는지 코드 기준으로 읽는다.

높은 Train과 흔들리는 Validation

학습 사진에는 잘 맞지만 일반화 차이가 남을 수 있다. jigsaw의 무작위성·큰 용량·학습 설정은 가능한 요인이지 그래프만으로 단일 원인을 입증한 것이 아니다. 마지막이 아니라 저장된 최고 Validation 체크포인트를 사용한다.

근거: web_skin_paper_suite.py:_fit_pmg_stage, _pmg_predictor

MixStyle과 MedSigLIP은 무엇이 다를까

하나는 학습 중 특징 통계를 섞고, 다른 하나는 사전학습 특징의 출발점을 바꾼다.

MixStyle

특징의 평균·표준편차 같은 스타일 통계를 섞어 조명·색감에 덜 의존할 가능성을 시험한다. 원본 픽셀과 라벨을 섞는 MixUp과 다르다. 실제 추론에서 두 사진을 함께 넣을 필요도 없다. Web Skin Accuracy 0.806, F1 0.8033767539683495로 기준선보다 소폭 유리했으나 PMG보다 낮았다.

MedSigLIP

의료 이미지와 텍스트를 embedding으로 바꾸는 사전학습 모델이다. 우리 실험은 448 입력의 영상 인코더를 고정하고 Linear head를 학습한 선별이다. 문장 생성 LLM이나 zero-shot 텍스트 선택지 실험이 아니다. 큰 본체를 직접 새로 사전학습하지 않았다.

고정 MedSigLIP Linear	Validation Accuracy	Validation Macro F1
Web Skin	0.824	0.8195774288599683
Hair5	0.7699680511182109	0.7687534259685547

선정과 패키지

두 도메인 모두 기존 최종 후보보다 낮아 교체하지 않았다. 저장된 작은 분류층 파일만으로 독립 추론할 수 없고 정확한 기반 모델 revision과 processor가 필요하다. 의료 사전학습이라는 이유만으로 우월하다고 판단하지 않은 사례다.

이해 확인

질문: MedSigLIP이 낮으면 의료 VLM도 안 좋은가?

답의 핵심: 그런 결론은 아니다. 모델 역할·학습 범위·평가 과제가 서로 다르다.

근거: R11, R12. 내부 D03, MedSigLIP 결과 문서

양호를 더한 Hair 6종은 새 과제다

분류 범위를 확장한 것이며 과거 5종 가중치에 출력 한 줄만 붙여 이어 학습한 결과가 아니다.

새 데이터

양호 사진 534장을 확보했고 기존 데이터와 파일·RGB 완전 일치는 없었다. 대응 JSON이 없어 여섯 증상 값이 모두 0이라는 라벨은 사용자 확인에 근거한다. 파일명에서 105개 ID를 추출해 그룹 분할했지만 독립적인 사람 수 확인과는 구분한다.

양호 데이터	원본	추가 변형
Train	428	2,140
Validation	53	없음
Test	53	없음

네 조건

ImageNet에서 새 6종 분류층을 만들고 B0·256·CE와 B1·384·LS 각각 원본/증강을 비교했다. 분류층 15회와 부분 미세조정 15회를 사용했다. 같은 모델 내에서도 Train 구성과 그 수량에 따른 클래스 가중치가 함께 바뀐다.

결론

B1 원본이 Validation Macro F1 선두였고 B0에서는 증강이 원본보다 높았다. B1에서는 증강이 낮았다. 따라서 증강이 항상 유리하지 않고, 5종과 6종은 Test·평균 구성 자체가 달라 성능 차이를 직접 개선량으로 계산하지 않는다.

이해 확인

질문: 양호 증강 2,140장은 새 사람 수인가?

답의 핵심: 아니다. 원본 Train에서 만든 변형 이미지 수다.

근거: 내부 D03, D04. hair_good_cross_audit, Hair6 결과

시간·크기·정확도와 최종 후보의 역할

빠른 모델과 정확한 모델이 같지 않을 수 있어 실행 비용도 별도로 측정했다.

실제 측정 범위

저장 조건 34개를 같은 환경에서 batch 1, 512×512 RGB 상수 이미지로 실행했다. 모델마다 준비 10회 뒤 지표별 30회 측정했다. 기존 Validation과 과거 학습 시간을 가져오고 지연만 새로 쟀다. 촬영·통신·파일 읽기·모델 로드·전체 앱 시간은 해당 추론 지연에 포함하지 않는다.

지표	뜻	해석
model p50	준비된 입력에서 출력까지 중앙값	보통 모델 지연
end-to-end p50	입력 변환부터 출력 동기화까지 중앙값	이번 코드 범위
p95	반복의 느린 쪽 95백분위	중앙값 외 꼬리 확인
학습 초	과거 학습 당시 경과 시간	같은 GPU 속도 순위 아님
파일 bytes	저장 체크포인트 크기	최대 VRAM과 다름

모델 간 분포

상자그림이 여러 모델 조건을 요약한다면 단일 모델의 반복 지연 안정성으로 읽지 않는다. GPU 제품명·전력·최대 메모리는 보존되지 않았다. MedSigLIP은 다른 프레임워크·정밀도도 사용해 순수 구조 속도 순위로 해석하지 않는다.

이해 확인

질문: 경량 후보는 항상 실제 Jetson에서도 빠른가?

답의 핵심: 이번 환경에서 낮은 비용을 보인 대안이다. 목표 장비의 전체 경로는 별도 측정이 필요하다.

근거: 내부 D05. benchmark.csv, environment.json

로봇팔 전체 흐름: 보기와 움직이기

이 부분은 팀원 발표자료의 구성과 결과를 학습용으로 풀어 쓴 것이다.

단계	담당 기능	결과
관측	카메라·Depth·마커	사진, 거리·기준 정보
속성 판단	VLM	종류·자세·파지 부위
위치 검출	YOLO	약통 상자·영상 좌표
좌표 변환	보정·TCP 기준	로봇이 이해할 목표
행동 예측	ACT 정책	시간에 따른 관절 행동
실행 확인	제어·Tracking Gate	실제 이동·파지·투입

VLA와 현재 구성

VLA는 영상·언어·행동을 연결하는 넓은 연구 방향이다. 팀 발표의 현재 구조는 인식·판단과 동작을 개별 개발·평가하는 방식이다. VLM 답변이 곧 관절 명령이 되는 완전한 통합 VLA를 완료했다고 바꿔 설명하지 않는다.

의료 AI와의 접점

의료 분류기는 검사 후보를, 로봇팔은 물리적 작업을 처리한다. 문장을 잘 생성하는 모델이 직접 의약품 선택과 물리 동작을 자동 확정하는 연결은 현재 자료로 확인되지 않았다. 서비스 결과와 동작 제어의 계약을 명시해야 한다.

이해 확인

질문: 사진을 잘 분류하면 로봇의 좌표 오차도 해결되는가?

답의 핵심: 아니다. 인식 이후 좌표 변환과 실제 관절 추종을 따로 검증해야 한다.

근거: 내부 D07. R14, R15

사진 라벨과 동작 시연 데이터

한 장의 정답 사진과 시간에 따른 행동 기록은 대체 관계가 아니다.

VLM·YOLO 자료

VLM은 종류·자세·파지 부위 같은 속성 라벨과 사진을 사용한다. YOLO는 위치 상자 라벨이 필요하다. 같은 사진이라도 평가 항목이 다르다. 영상에서 추출한 JPEG는 정지 장면 자료가 되지만 그 자체가 연속 동작 시연이 되지는 않는다.

ACT 자료

카메라 영상과 관절 상태, 사람이 시연한 행동을 시간에 맞춰 기록한다. Episode는 한 번의 시연이다. 카메라 수·해상도·시간 동기·관절 단위·시작 자세가 달라지면 같은 행동도 다른 입력 분포가 될 수 있다.

팀 발표의 기록	구성	단위 주의
VLM 선정 자료	585장: Train 375 / Val 99 / Test 111	초기 1,226 레코드와 구분
한 ACT 구성	3카메라·약통별 각 60회	시연 횟수
다른 ACT 구성	2카메라·초기 50회/후속 100회	다른 수집본
학습 기록	10,000·30,000·후속 100K	조건별 update 기록

분할 방법

같은 시연에서 잘라낸 인접 프레임이 Train과 Test로 나뉘면 유사 장면을 외운 결과가 섞인다. 사진 행보다 episode·세션·물체 조건을 묶어 평가하는 이유다. 현재 팀 원본 전체의 분할을 이 책 작성에서 재검증한 것은 아니다.

근거: 발표 실제 16~18쪽. D07

YOLO는 약통의 위치를 찾는다

분류 점수만이 아니라 이미지 안에서의 위치가 출력된다.

상자와 IoU

Bounding box는 물체를 둘러싼 사각형이다. 예측 상자와 정답 상자의 겹침을 합집합으로 나눈 것이 IoU다. 정확한 종류와 충분한 위치 겹침을 함께 만족하는지를 평가한다. 상자 좌표는 이미지 픽셀 좌표이지 로봇 관절 목표가 아니다.

지표 읽기

Precision은 검출한 것 중 맞은 비율, Recall은 실제 물체 중 찾아낸 비율이다. AP는 점수 임계값을 바꾸며 얻은 정밀도·재현율 곡선을 요약한다. mAP50은 IoU 0.5 기준, mAP50-95는 여러 엄격한 겹침 기준을 종합한다.

팀 발표 평가	Precision	Recall	mAP50	mAP50-95
Val 18장	0.995	1.000	0.995	0.766
smoke Test 11장	0.995	1.000	0.995	0.798

확인 범위

YOLO11n·입력 640·batch 8 조건의 단일 약통 위치 검출이다. A·B·C 종류 분류나 전체 파지 성공률과 다르다. 작은 smoke 시험은 우선 동작 여부를 확인하는 성격이며 독립 환경의 오검출률을 충분히 입증하지 않는다.

이해 확인

질문: mAP50 0.995를 바구니 투입 성공률 99.5%라고 읽어도 되는가?

답의 핵심: 안 된다. 지표의 과제가 완전히 다르다.

근거: R14. 발표 17·61쪽 보고값

로봇 VLM의 종류·자세·파지 판단

어디 있는지와 무엇인지, 어떻게 잡을지는 서로 다른 질문이다.

모델이 답하는 항목

종류는 A·B·C 등 목표 범주, 자세는 놓인 방향·상태, 파지 부위는 잡을 후보 영역이다. 출력이 문장 또는 구조화 값이어도 물리적으로 잡을 수 있는지는 별도 시험해야 한다. 속성 라벨을 바탕으로 학습할 수 있으나 동작 성공 정답을 자동으로 얻는 것은 아니다.

팀 발표 조건	종류 정확도	자세 정확도	파지 정확도
9/25 재학습	23.4%	42.3%	61.3%
9/26 v5	36.9%	79.3%	81.1%
9/26 이중 어댑터	별도 평가 대상	84.7%	81.1%

어떻게 설명하나

자세·파지 속성에는 개선이 보이지만 종류 판단은 어렵게 남았다. 한 항목의 높은 점수는 세 항목 동시 정답률이 아니다. 이 표는 팀원 발표 보고값이며 같은 평가 세트·추론 조건 여부를 원본에서 확인해야 엄격한 전후 비교가 가능하다.

의료 VLM과 분리

약통 속성 VLM과 사진에서 피부질환을 분류할 독립 의료 VLM은 입력·라벨·목표가 다르다. 같은 "VLM"이라는 이름만으로 한쪽의 성능을 다른쪽에 옮겨 말할 수 없다.

근거: 발표 60쪽. D07

카메라 좌표·마커·TCP와 보정

화면에서 오른쪽이라는 말과 로봇 관절의 움직임은 같은 좌표계가 아니다.

좌표계가 여러 개인 이유

이미지 좌표는 픽셀 위치, 카메라 3D 좌표는 센서 기준 거리, 작업대 좌표는 작업대 기준, 로봇 좌표는 로봇 기준이다. 실제 목표를 전달하려면 이 기준 사이의 회전·이동 관계가 필요하다. 깊이 센서가 있어도 기준 변환이 자동으로 정확해지는 것은 아니다.

개념	역할	팀 자료 연결
마커	알려진 기준점 관측	작업대 ID 0~3, 바구니 ID 4~6
캘리브레이션	센서·기준 관계 추정	카메라·작업대·로봇 기준
TCP	도구의 기준점	PIN TIP과 GRASP 기준 구분
RMS	오차 크기 요약	어떤 잔차인지 명시

TCP가 중요한 이유

핀 끝을 기준으로 계산한 위치와 물체를 잡는 중심 기준은 다를 수 있다. 기준을 혼용하면 인식 위치가 맞아도 그리퍼가 빗나갈 수 있다. 좌표 보정의 작은 잔차와 실제 끝점 도달 오차도 같은 수치가 아니다.

이해 확인

질문: 보정 RMS 5.429mm면 실제 그리퍼도 항상 그 범위에 도달하는가?

답의 핵심: 아니다. 보정 데이터의 잔차와 실제 로봇 동작의 절대 오차는 따로 평가해야 한다.

근거: 발표 17·63·66쪽. 일반 원리를 팀 자료와 구분

ACT: 행동을 여러 시점 묶음으로 예측하기

Action Chunking with Transformers는 사람이 보여준 행동 시퀀스를 학습하는 모방학습 방법이다.

왜 한 행동씩만 예측하지 않나

현재 관측에서 다음 행동 한 개만 예측하면 작은 오차가 누적될 수 있다. ACT의 핵심은 여러 시점의 행동 묶음을 생성하는 것이다. 원논문은 저비용 하드웨어와 시연 기반 정밀 조작을 다뤘다. 해당 논문의 성공률을 팀 로봇의 성공률로 가져오지 않는다.

Transformer와 시간

Transformer는 입력 요소 사이의 관계를 attention으로 다루는 모델 계열이다. ACT에서는 영상·관절 등 관측에서 시간에 따른 행동을 예측한다. 세부 원논문에는 시연의 다양성을 다루는 잠재 표현과 시간적 결합이 있지만, 현재 팀의 활성 설정은 원본 config로 확인해야 한다.

입력·출력	예시	뜻
관측	여러 카메라 영상·현재 관절	현재 작업 상태
학습 정답	시연한 미래 관절·행동 시퀀스	따라 배울 행동
예측	다음 여러 시점의 행동 묶음	실제 제어기에 전달할 후보

이해 확인

질문: ACT는 사람이 매 순간 정답 질환 라벨을 붙이는 학습인가?

답의 핵심: 아니다. 시연 관측과 행동의 대응을 배우는 모방학습이다.

근거: R15, R16. 발표 18·62쪽

ACT Loss와 실제 파지 성공이 다른 이유

시연과 비슷한 행동을 예측하는 것과 실제 환경에서 작업을 끝내는 것은 같지 않다.

학습 지표

행동 예측 오차 같은 학습 목적이 작아지면 시연을 더 잘 맞출 수 있다. 하지만 실행 중 관측이 시연 범위를 벗어나면 오차가 커질 수 있다. 카메라 배치·시작 자세·물체 위치·그리퍼 접촉이 모두 영향을 준다.

실제 팀 자료

세 카메라 정책의 초기 10,000 step Loss 감소와 Jetson 적용 시험이 보고됐다. 약통 C 동작 실패도 있었다. 약통 A의 후속 100K 기록은 다른 조건이며 C 실패와 하나의 연속 원인·해결로 묶지 않는다.

시작 자세와 대기 구간

시연 시작의 가만히 있는 구간을 많이 학습하면 실제 실행도 움직임이 늦어질 수 있다는 가설을 검토할 수 있다. 팀의 trim05·A-v3 비교는 이런 시작 구간과 시연 구성의 후속 검토다. 그래프만으로 지연의 유일한 원인을 확정하지 않는다.

측정할 성공 단계

목표 접근, 실제 파지, 들어 올리기, 이동, 바구니 놓기를 각각 기록하면 어디서 실패하는지 알 수 있다. 하나의 영상 성공 사례를 반복 성공률로 발표하지 않는다. 분모·초기 조건·중단 기준이 필요하다.

이해 확인

질문: 학습 완료·모델 로드 성공이면 로봇 작업도 성공한 것인가?

답의 핵심: 아니다. 실제 closed-loop 작업의 반복 시험이 별도로 필요하다.

근거: 발표 18·62~66쪽. R15

Tracking Gate와 실제 움직임 확인

명령을 보냈다는 사실보다 실제 관절이 얼마나 따라왔는지를 확인하는 제어 관점이다.

목표와 실제 관절

명령 목표와 센서가 읽은 현재 관절 상태의 차이가 크면 다음 동작을 진행하기 이르다. Tracking Gate는 이런 조건을 확인하며 진행 여부를 제한하는 방식으로 이해하면 된다. 새 시각 분류기를 학습하는 방법과는 다르다.

팀 자료의 문제 대응

팔이 도달하기 전에 그리퍼가 열리는 현상, 팔꿈치 지연 약 21.1도, 중단 때 토크 처리 문제 등이 기록됐다. 목표·실제 상태를 비교하거나 종료 시 현재 위치·토크를 유지하도록 수정한 기록이 있다. 비동작 시험과 실장비 효과 확인은 구분한다.

0.79의 정확한 뜻

66쪽의 0.79는 추종 오차를 허용 한계로 나눈 비율이다. 1 이하 기준 통과를 나타내며 성공률 79%가 아니다. 접근 경로 통과는 실제 파지·투입 성공과 별도다.

안전한 연구 설명

이 책은 동작 원리를 이해하는 자료다. 실제 토크·속도·관절 제한값을 새로 지시하거나 설정을 바꾸지 않았다. 실제 제어 설정은 담당자가 원본 하드웨어 조건에 맞춰 검증해야 한다.

이해 확인

질문: 분류 Confidence를 높이면 관절 추종 지연도 줄어드는가?

답의 핵심: 서로 다른 단계의 문제다. 인식 품질과 제어 피드백을 분리해 확인한다.

근거: 발표 63·66쪽. 팀 보고 범위

로봇 결과와 아직 남은 평가

단계별 확인을 구분하면 성과와 남은 과제를 과장 없이 설명할 수 있다.

팀 발표 기록	보고값·상태	이것과 다른 것
관측	300프레임·약 28.372fps	전체 작업 처리량
깊이 평면 잔차	RMS 1.475mm	그리퍼 절대 도달 오차
Table-Robot 보정	RMS 5.429mm	작업 전체 성공률
실제 구동	파지 확인 사례 있음	반복 투입 완료
후속 상태	관절 지연·안정적 투입 미완료	완전 자동 통합

다음 실험의 형태

같은 초기 조건을 정해 반복하고, 단계별 성공 수·전체 시도 수·실패 유형·작업 시간을 기록한다. 다른 물체 배치나 조명 변화는 별도 조건으로 둔다. 학습 데이터에 등장한 장면과 새 장면의 결과도 나눠 보면 일반화를 확인하기 쉽다.

발표 영상

현재 검토한 PPT 64·65쪽에는 실제 동영상 파일과 외부 연결이 없었다. 영상 자리의 제목만으로 성공 동작을 추정하지 않는다. 실제 시연을 추가할 때 조건과 성공 단계가 일치하는지 확인한다.

발표에서는 이렇게

인식과 동작 학습, 좌표·구동의 개별 검증을 진행했으며 안정적인 파지·이동·투입의 반복 평가와 통합이 남았습니다.

근거: 내부 D07. 원본 로봇 로그 재실행 아님

LLM은 문장을 토큰으로 배우는 모델

분류기는 정해진 클래스 점수를 내고, LLM은 앞 문맥을 바탕으로 다음 토큰을 생성한다.

토큰과 문맥

토큰은 모델이 읽고 쓰는 텍스트 조각이다. 한글 한 글자나 한 단어와 항상 일치하지 않는다. Context length는 한 번에 다룰 수 있는 입력·출력 범위와 연결된다. 긴 입력과 긴 출력은 메모리와 지연에도 영향을 준다.

Transformer와 attention

문맥의 요소 사이 관계를 attention으로 계산하는 계열이 현재 LLM의 중요한 기반이다. Attention이 있다고 자동으로 사실을 확인하는 것은 아니다. 모델은 문장 형식과 지식을 배울 수 있지만 입력에 없는 내용을 그럴듯하게 생성할 수도 있다.

명령·파일	불러오는 것	구분
Tokenizer	텍스트↔토큰 규칙	질환 지식 데이터 자체 아님
Model weights	사전학습된 숫자	프롬프트와 다름
Chat template	역할·대화 직렬화 규칙	모델별로 다름
Adapter	추가 학습한 작은 가중치	보통 기반 모델 필요

이해 확인

질문: LLM 답이 자연스러우면 입력 결과도 정확히 보존했는가?

답의 핵심: 별도 확인해야 한다. 문장 유창성과 수치·라벨 충실성은 다르다.

근거: R16. 내부 D06, D08

우리 설명 LLM과 독립 VLM의 두 경로

두 경로의 역할과 정답을 섞지 않는 것이 연구 설계의 핵심이다.

경로	입력	평가할 것
설명 LLM	전문 분류 결과 + 문진 + 질문	수치·라벨 보존, 쉬운 설명, 정보 혼용 방지
독립 VLM	사진 + 도메인 + 허용 클래스·질문	질환 분류와 시각 근거
향후 결합 실험	사진 + 분류기 결과	독립 평가 후 별도 조건으로 비교

설명 경로

웹캠·현미경 사진을 맞는 전문 분류기로 처리하고, 결과 JSON과 사용자의 문진을 LLM에 전달한다. 분류기가 틀려도 LLM이 정답 라벨을 몰래 받아 고쳐 말하면 결과 설명 평가가 아니다. 실제 예측을 충실하게 읽는지 먼저 본다.

독립 판단 경로

VLM에는 사진 자체와 과제 정보를 준다. 기존 분류기의 예측을 주지 않아야 독립 비교가 된다. 분류용 정답은 학습·채점에만 두고 질환명이 드러나는 파일 경로를 질문에 넣지 않는다.

현재 단계

기존 전문 모델 결과는 확보돼 있다. 한국어 결과 설명과 피부·두피 독립 VLM은 앞으로 준비할 우리 과제다. 팀원의 의료 QA·방사선 VQA 결과를 이미 완료한 피부·두피 성능으로 바꾸지 않는다.

근거: 내부 D06, D08. ROADMAP 13·14단계

프롬프트·RAG·SFT를 구분하기

모두 모델을 활용하는 방법이지만 바꾸는 위치가 다르다.

방법	무엇을 바꾸나	이번 프로젝트의 위치
프롬프트	입력 지시·예시·출력 형식	첫 설명 평가에서 고정
RAG	검색한 문서를 입력 근거로 추가	필요한 지식 오류에 후속 비교
SFT	정답 응답 예시로 가중치 학습	설명 오류 확인 뒤 검토
LoRA/QLoRA	적은 자원으로 가중치를 조정하는 방식	SFT를 수행하는 구현 수단

프롬프트

역할·해야 할 일·사용할 입력·출력 형식을 명시한다. 가중치가 새로 학습되는 것은 아니다. 같은 모델에서도 프롬프트가 바뀌면 답이 달라지므로 비교할 때 버전을 기록한다.

RAG

검토된 문서를 검색해 관련 내용을 답변 입력에 넣는다. 모델 가중치를 자동 갱신하는 방법은 아니다. 검색이 틀리거나 근거를 잘못 읽으면 오류가 남는다. 첫 결과 설명 과제에 필수인 것은 아니다.

SFT와 목표

입력과 올바른 응답의 짝으로 지도학습한다. 의료 QA는 일반 질문에 답하는 목표이고, 우리 설명 SFT는 분류 결과·문진을 보존하며 설명하는 목표다. 목표가 달라 별도 자료와 평가가 필요하다.

이해 확인

질문: 프롬프트를 잘 쓰면 미세조정을 한 것인가?

답의 핵심: 아니다. 입력 설계와 가중치 추가 학습은 구분한다.

근거: R17~R19. 내부 D06, D08

SFT 데이터와 답변 토큰 마스킹

문장 전체를 복사하게 할지, 올바른 답변을 학습하게 할지 학습 목표를 분명히 해야 한다.

입력·정답 쌍

질문·문맥·이미지는 입력이고 assistant의 검수된 답변이 학습 정답이다. 정답을 사용자 입력에 넣으면 문제를 푸는 대신 답을 읽는 자료가 된다. provenance는 출처·원본 ID·버전 같은 추적 정보이며 정답과 함께 별도 관리한다.

마스킹의 의미

답변 토큰만 학습하려면 프롬프트·padding·이미지 토큰에 손실을 주지 않도록 표시한다. 흔히 labels=-100 같은 제외값을 사용한다. attention mask는 어떤 토큰을 볼지, loss mask는 어디를 정답 학습할지에 관련돼 같은 개념이 아니다.

```
# 동작 설명용 예시
messages = [system_instruction, user_input, gold_answer]
tokens = native_chat_template(messages)
labels = copy(tokens)
labels[prompt_or_padding_or_image_positions] = -100
loss = next_token_loss(model(tokens), labels)
```

팀 코드에서 확인한 점

MedVLM은 모델 native chat template와 실제 토큰 경계를 확인하고 답변 중심 학습을 구현했다. 이미지 encoder와 projector를 기본 고정한 언어 LoRA 경로도 검사한다. 구현이 있다고 모든 새 도메인 결과가 검증된 것은 아니다.

이해 확인

질문: 이미지에서 생성한 설명을 검수 없이 정답으로 쓰면 되는가?

답의 핵심: 생성 오류가 학습 정답으로 굳을 수 있다. 분류 라벨과 시각 설명의 근거는 별도 검수가 필요하다.

근거: R18. 팀 고정 코드 rendering.py, models.py

LoRA: 작은 추가 행렬을 학습하기

Low-Rank Adaptation은 큰 기반 가중치 전체 대신 작은 변화량을 학습한다.

구조의 개념

기반 행렬 W를 고정하고 변화량을 작은 두 행렬의 곱 BA로 표현한다. 설명식은 W_new = W + scale × B × A 다. rank r은 작은 내부 차원이다. 원본 전체를 새로 학습하는 것보다 학습 가능한 파라미터와 optimizer 상태를 줄일 수 있다.

```
# 원리 설명용 축약 코드
lora = LoraConfig(
    r=8, lora_alpha=16, lora_dropout=0.05,
    target_modules=language_projection_modules)
model = get_peft_model(base_model, lora)
```

팀 구현의 의미

2026-10-26 고정 코드에는 언어 모듈의 q/k/v/o projection과 MLP projection 후보를 선택하고, 영상 ·projector 영역을 제외하는 정책이 있다. rank 8·alpha 16·dropout 0.05는 코드 기본값이며 모든 팀 실행이 동일한 값이었다고 단정하지 않는다.

Hair 미세조정과 비교

Hair는 기존 본체 후반부의 가중치 자체를 갱신했다. LoRA는 본체를 고정한 채 작은 추가 가중치를 학습한다. 둘 다 넓게는 과제 적응이지만 갱신하는 대상과 저장 방식이 다르다.

이해 확인

질문: adapter 파일만 다른 아무 LLM에 붙일 수 있는가?

답의 핵심: 보통 불가능하다. 같은 기반 모델·revision·구조와 대상 모듈, tokenizer 정보를 맞춰야 한다.

근거: R17. 팀 models.py 고정 커밋 e16f8c6...

QLoRA·양자화·메모리 이해하기

QLoRA는 양자화한 기반 모델을 고정하고 LoRA를 학습하는 접근이다.

왜 양자화하나

큰 모델의 가중치를 낮은 비트 표현으로 보관하면 메모리를 줄일 수 있다. 실제 계산은 다른 dtype을 사용할 수 있다. "4bit 모델"이라고 모든 메모리와 모든 연산이 정확히 4bit가 되는 것은 아니다.

팀 코드

NF4 설정에서는 load_in_4bit, double quantization, compute dtype을 지정하고 k-bit 학습 준비를 수행한다. gradient checkpointing으로 일부 중간 결과를 다시 계산해 메모리와 계산량을 절충한다. 실제 지원과 사용량은 모델·환경별로 확인한다.

메모리 요소	하는 일	줄이는 방법의 예
가중치	모델 파라미터	양자화
optimizer·gradient	학습 갱신 상태	LoRA로 학습 대상 축소
활성화	학습 중 중간 결과	batch·길이·checkpointing
KV cache	생성 중 이전 토큰 상태	문맥·동시 요청·추론 설정

혼동하지 않기

QLoRA는 자동으로 더 정확한 질환 모델을 만드는 알고리즘이 아니다. 적은 자원으로 추가 학습하는 방식이다. GPU에서 가능했던 설치를 Jetson에 그대로 복사해 실행할 수 있다고 가정하지 않는다.

이해 확인

질문: 4bit를 쓰면 GPU 메모리가 무조건 원래의 1/4인가?

답의 핵심: 아니다. 저장 정밀도 외의 상태와 활성화·캐시·구현 비용이 있다.

근거: R19. 팀 models.py, 내부 D06

VLM은 이미지 특징을 언어 모델과 연결한다

모델별 구조는 다르지만 이미지 인코더·연결부·언어 모듈로 이해하면 출발하기 좋다.

일반적인 경로

이미지를 processor로 준비하고 vision encoder가 특징으로 바꾼다. projector 또는 모델별 연결 방식으로 언어 모듈이 사용할 표현을 만든다. 질문과 이미지 표현을 함께 읽어 답변 토큰을 생성한다. 모든 VLM이 완전히 같은 연결 구조라는 뜻은 아니다.

부분	역할	추가 학습의 선택
Vision encoder	사진 특징 추출	고정하거나 일부 학습
연결부	영상·언어 표현 연결	모델별 설정 확인
Language modules	질문과 특징에서 답 생성	LoRA 대상 가능
Processor/template	이미지·대화 입력 규격	기반 모델과 함께 보존

프로젝트에서의 구분

팀 SLAKE 학습은 CT·MRI·X-ray 중심 VQA다. 우리가 앞으로 할 얼굴·확대 피부·두피 질환 분류는 다른 도메인이다. 의료 VLM이라는 이름은 비교할 이유가 되지만 성능 보증은 아니다.

출력과 정답

클래스 라벨은 분류 정답으로 쓸 수 있지만 라벨 하나로 각질 크기·홍반 위치까지 정답 문장을 만들 수는 없다. 분류 정확도와 시각 설명의 근거성을 따로 채점한다.

이해 확인

질문: CNN 예측 라벨을 VLM에 주면 독립 분류 비교인가?

답의 핵심: 아니다. 그것은 별도의 결합 실험이다.

근거: 내부 D06, D08. R12, R23

팀원은 어디까지 실제 학습했나

다음 표는 2026-10-26 저장소 점검에 보존된 팀원의 공개 보고값이다.

모델·평가	Base 정답	Tuned 정답
Qwen3-1.7B · PubMedQA	209 / 500	372 / 500
Qwen3-4B · PubMedQA	177 / 500	384 / 500
Qwen3.5-2B · SLAKE exact match	88 / 256	185 / 256
MedGemma 1.5 · SLAKE exact match	0 / 256	179 / 256
Qwen3.5-2B · VQA-RAD exact match	19 / 64	31 / 64
MedGemma 1.5 · VQA-RAD exact match	0 / 64	30 / 64

왜 0점 해석을 조심하나

MedGemma base는 한 단어 정답에 긴 문장으로 답하거나 출력 상한에 도달한 사례가 있었다. exact match 0은 문자열이 정확히 같지 않았다는 뜻이지 모든 의료 내용을 틀렸다는 뜻이 아니다. 개선에는 형식 적응 효과도 있을 수 있다.

완료 수와 데이터 수

공개 기록에서 텍스트 2모델은 각 525 updates, 처리 sample 8,400회이고 VLM 2모델은 각 124 updates·1,979 sample이다. 처리 횟수와 고유 사례 수는 다르다. canonical 19,866개를 모두 Train에 넣었다는 뜻도 아니다.

우리에게 남은 평가

한국어 분류 결과 설명, 얼굴·두피 VLM 정확도는 이 표가 증명하지 않는다. 팀원 PC 원본 가중치 재로드나 GPU 학습을 이번 PDF 제작에서 수행하지 않았다.

근거: 내부 D06. 팀 공개 결과 고정 커밋 e16f8c6...

Forge 대시보드·MedVLM·GitHub의 역할

화면, 학습 엔진, 모델, 서비스 서버는 서로 다른 구성요소다.

도구·저장소	주요 역할	자동으로 보장하지 않는 것
mediflow-datasets	기존 Keras 모델·평가·전처리	새 LLM 학습
mediflow-medvlm	모델 로드·데이터·학습·평가	현재 한국어 피부 설명 성능
Forge	지원 모델 학습 관리 UI·GPU worker	학습 후 추론 서비스
kiosk-core	촬영·문진·결과 화면·저장	모델 품질과 실제 장비 검증
GitHub	코드·문서·버전 협업	대용량 모델 자체의 자동 실행

고정 버전

당시 실제 의료 학습 코드는 MedVLM의 codex/medical-finetune-v1-20261023 브랜치에 있었다. main만 받으면 같은 상태가 아니다. Forge의 학습 UI와 실제 의료 학습 native 실행 경로도 구분한다. 현재 원격 최신 상태를 이번에 새로 점검한 것은 아니다.

Forge 입력 한도

당시 점검 코드에는 JSONL 128KiB·1,000행, 이미지당 2MB·16MP, snapshot 합계 128MB, 이미지 thumbnail 최대 384, 문맥 최대 2,048토큰 등의 한도가 있었다. 큰 Hair 분류 ZIP을 그대로 올리는 Colab 학습과 사용법이 다르다.

이해 확인

질문: GitHub에 모델 사용법을 올리면 웹 서비스가 바로 완성되는가?

답의 핵심: 아니다. 모델 파일·환경·추론 서버·입력 계약·평가·UI 연결이 필요하다.

근거: 내부 D06, D08. 저장소 URL은 참고문헌

설명 LLM 평가: 말을 잘하는 것 이상

가장 먼저 평가할 것은 기존 결과를 정확히 읽고 없는 정보를 만들지 않는 능력이다.

비교 설계

같은 Qwen3-4B base와 팀 의료 QA adapter를 동일한 결과·문진·프롬프트·생성 상한·정밀도에서 비교하는 첫 실험이 제안돼 있다. 새 학습부터 반복할 필요는 없다. 결과 설명 오류가 확인되면 그 오류를 겨냥한 추가 SFT를 검토한다.

평가 항목	확인할 것
결과 충실성	클래스·점수·모델·result ID 보존
정보 없음	미입력 증상·기간을 만들지 않음
오류 입력	실행 실패를 유효 라벨로 채우지 않음
문진 구분	분류 결과와 사용자 진술의 출처 분리
표현 품질	한국어 이해 가능성과 불필요한 단정
출력 계약	JSON 필수 필드·상태·타입

VLM 평가는 별도

같은 도메인의 같은 사진과 라벨 정의를 사용해 클래스 Accuracy·Macro F1·Recall·혼동을 본다. 형식 오류·답변 실패도 분모에서 빼지 않는다. 이미지 포함/제외 비교는 실제 시각 입력을 쓰는지 살펴볼 수 있지만 곧 완전한 인과 증명은 아니다.

이해 확인

질문: Loss가 줄면 우리 설명 기능도 더 좋아졌는가?

답의 핵심: 별도 설명 평가를 해야 한다. 토큰 예측 손실과 라벨·수치 충실성은 같은 지표가 아니다.

근거: 내부 D06, D08

LLM 지연·처리량·컨텍스트 비용

이미지 분류기의 한 번 출력과 문장 생성의 시간 구조는 다르다.

지표	뜻	조건
첫 토큰 시간	응답 첫 조각까지 대기	입력 길이·모델 로드 구분
전체 응답 시간	답변 완료까지	출력 토큰 상한과 실제 길이
tokens/s	단위 시간 생성량	모델·batch·정밀도
동시성	동시에 처리하는 요청 수	대기와 메모리 영향
최대 메모리	실행 중 최고 사용량	가중치 파일 크기와 다름

비교 조건

같은 질문·입력 길이·출력 제한·장치·정밀도·batch·warmup을 기록한다. 긴 답변을 생성한 모델이 총시간이 길다고 계산 자체가 항상 느린 것은 아니다. 스트리밍 첫 토큰과 완료 시간도 따로 본다.

환경 분리

기존 분류기는 TensorFlow/Keras, 팀 언어 모델은 PyTorch/Transformers/PEFT 경로다. 한 환경에 모든 버전을 억지로 맞추기보다 기능별 환경과 JSON 교환을 명확히 하는 편이 재현에 유리하다. Linux CUDA 학습 기록을 Windows·Jetson 성능으로 옮기지 않는다.

이해 확인

질문: 분류 지연 300ms와 LLM 첫 토큰 300ms는 같은 성능인가?

답의 핵심: 아니다. 포함 범위와 출력 작업이 다르므로 직접 순위를 매기지 않는다.

근거: 내부 D05~D08

분류 결과를 LLM에 어떻게 전달할까

다음은 형식을 이해하기 위한 가상 예시이며 실제 서비스 계약의 확정본이 아니다.


```
{
  "result_id": "example-001",
  "domain": "hair",
  "task_id": "hair_6class_primary",
  "status": "ok",
  "candidate_id": "fixed-candidate-id",
 "predicted_label": "비듬",
 "questionnaire": {"itching": "미입력"}
}
```


실제 계약에는 더 필요하다

클래스 배열 순서·원본 점수·예측 인덱스, 모델 SHA·전처리 버전, 장비·촬영 부위, 오류 상태도 보존한다. score 배열과 라벨 배열의 순서가 다르면 설명이 틀린 질환으로 연결될 수 있다. Hair5와 Hair6는 task ID로 구분한다.

정답은 입력에 넣지 않는다

평가용 true_label이나 질환명이 드러나는 경로를 LLM에 주면 설명·독립 판단 평가가 오염될 수 있다. 문진이 없으면 미입력이라고 남긴다. 사용자 입력 문자열 속의 지시문과 시스템 지시도 구분한다.

의료적 판단과 모델 출력

LLM이 분류 점수를 확진 확률이나 실제 위험도로 바꿔 말하지 않게 한다. 현재 실험의 출력 범위와 근거를 설명하는 것이 첫 목표다. 자동 처방·로봇 명령으로 연결된 구현은 이 책의 완료 범위가 아니다.

근거: 내부 D08. 현재 제안, 구현 완료 아님

한 가지 가설을 비교하는 실험 설계

새로운 방법을 많이 적용하는 것보다 결과를 해석할 수 있게 비교하는 것이 중요하다.

실험 예	가능하면 고정	바꾸는 것
Hair 미세조정	데이터·본체·입력·Loss	학습 범위와 명시한 동반 설정
Web PMG 비교	같은 분할·B0·256	학습·구조 경로
로봇 Gate	같은 물체·시작·경로	진행 확인 로직
설명 LLM	같은 사례·프롬프트·출력 제한	base 또는 adapter
독립 VLM	같은 사진·클래스·split	모델·native 처리 차이 기록

동반 변경은 숨기지 않는다

큰 PMG에는 메모리를 위해 batch를 줄였다. Hair6 원본/증강 비교는 클래스 가중치와 epoch당 갱신 수도 달라질 수 있다. 현실적으로 완전히 한 값만 바꾸지 못하면 그 이유를 기록하고 조합 전체의 결과로 해석한다.

기록의 최소 구성

데이터 버전·해시, split·그룹 기준, 클래스 순서, 코드 커밋과 미커밋 변경, 환경·seed·설정, 시작 모델·체크포인트·선택 기준, Validation과 고정 Test 결과를 남긴다. 표·그래프를 새로 만든 것을 새 학습으로 집계하지 않는다.

이해 확인

질문: 같은 Test에서 계속 좋은 모델을 고르면 객관적인가?

답의 핵심: 선택 과정에 반복 사용한 Test는 더 이상 독립 최종 확인 역할을 충분히 하지 못한다.

근거: AGENTS.md, ROADMAP. 내부 D01~D08

발표할 때 방법을 설명하는 네 문장

문제·원리·적용·결과를 한 묶음으로 말하면 이름 나열을 피할 수 있다.

미세조정

일반 이미지 특징을 고정한 방식으로는 미세 질환 차이 구분에 한계가 있었습니다. 그래서 분류층 학습 후 특징 추출부 후반부도 낮은 학습률로 조정했습니다. 데이터와 다른 설정 변화도 포함돼 상승 전체를 미세조정 한 가지로 분리하지는 않습니다.

PMG

얼굴의 작은 피부 단서를 여러 크기로 학습하려고 PMG를 응용했습니다. 여러 jigsaw 분기와 원본 결합 경로를 학습했습니다. Validation에서 유망했고 실행 비용을 고려해 B0·256을 전달 후보로 남겼습니다.

ACT

사진의 판단뿐 아니라 실제 움직임이 필요해 시연의 영상·관절·행동 대응을 학습했습니다. 학습 Loss와 실제 작업 성공을 따로 확인했습니다. 접근과 파지 사례 뒤 안정적인 반복 이동·투입이 남았습니다.

LLM·LoRA

기존 분류 결과와 문진을 쉬운 말로 설명하려고 LLM을 사용하려 합니다. 먼저 기존 base와 팀 의료 QA adapter를 같은 사례에서 비교합니다. 필요한 오류가 확인되면 검수한 설명 예시로 추가 SFT를 하고 LoRA/QLoRA를 학습 수단으로 사용할 수 있습니다.

이해 확인

질문: "논문에서 좋은 방법이라 사용했다"에서 무엇을 더해야 하나?

답의 핵심: 우리 데이터의 어떤 문제를 겨냥했는지, 실제로 무엇을 바꿨고 결과로 채택했는지를 덧붙인다.

근거: 학습용 정리. 완료·계획 구분 유지

스스로 답해 볼 핵심 질문

아래 답을 보지 않고 먼저 한두 문장으로 설명해 본다.

질문	답의 핵심
새 분류층과 미세조정의 차이?	출력층 교체·학습과 특징 추출부 일부 가중치 갱신
증강하면 왜 항상 좋아지지 않나?	라벨 보존·변형 강도·독립 다양성·갱신량 차이
LS와 Focal의 차이?	목표 분포 완화와 쉬운 표본의 손실 기여 축소
SupCon과 PMG의 차이?	특징 간 관계와 다중 크기 분기 학습
SAM과 Segment Anything은 같은가?	이 책의 SAM은 최적화 방법 Sharpness-Aware Minimization
분류·검출·행동의 차이?	무엇인가·어디인가·어떻게 움직이는가
ACT Loss가 낮으면 성공인가?	실제 반복 작업 성공은 별도
프롬프트와 SFT의 차이?	입력 지시 변경과 가중치 학습
LoRA와 QLoRA의 차이?	작은 변화량 학습과 양자화 기반 모델 활용
어댑터만 있으면 완성 모델인가?	기반 모델·revision·processor 등 필요
설명 LLM과 독립 VLM의 차이?	분류 결과 설명과 사진에서 별도 판단
최종 다음 단계는?	우리 과제 입력·평가 자료와 실제 연결 계약 준비

마지막 점검

원논문이 말한 효과, 프로젝트가 측정한 효과, 앞으로 확인하려는 가설을 구분해 말할 수 있으면 연구 내용을 이해한 것이다. 불확실한 원인을 확정하지 않고 어느 비교에서 무엇을 확인했는지 답하는 연습이 중요하다.

근거: 본편 전체

Hair v1: 여섯 기본 조건의 원본 값

같은 Clean Validation 1,252장의 저장 Accuracy다. 이 묶음에는 Validation Macro F1이 없어 별도 값으로 채우지 않았다.

조건	Validation Accuracy
B0·224·CE	0.7643769979476929
B0·256·CE	0.7699680328369141
B0·256·LS 0.05	0.7739616632461548
B0·256·Focal 1.5	0.7675718665122986
B1·256·LS 0.05	0.7763578295707703
B1·256·LS·추가 5회	0.7771565318107605

선정

B1·256·LS·추가 5회가 당시 Accuracy 기준 선두였다. 이 표의 기준과 SupCon 비교용으로 새로 저장한 B1·256 기준선은 다르다.

단계별 비교

B0·224→256은 입력, CE→LS/Focal은 손실, B0→B1은 구조 구성, +5회는 후속 학습을 시험했다. 초기 정제 전 모델과 이 표의 Clean 결과를 같은 분할로 오해하지 않는다.

근거: benchmark.csv + hair/selected_models/v1/selection.json

Web Skin v1: 여섯 기본 조건의 원본 값

같은 원본 Validation 500장과 Accuracy 우선 동률 규칙의 결과다.

조건	Validation Accuracy	Validation Macro F1
b0_224_ce	0.794	0.7917009497301795
b0_256_ce	0.796	0.7915394647566528
b0_256_ls005	0.794	0.7892883497449976
b0_256_focal15	0.792	0.7898148816790076
b1_256_ls005	0.796	0.7931535064807589
b1_256_ls005_extend5	0.796	0.7931535064807589

동률과 연장

B0·256·CE와 B1이 Accuracy 동률이라 앞선 조건을 유지했다. 마지막 extend5 행은 parent_stage2이며, 새 연장 모델이 부모 최고를 넘지 못해 보존된 값이다. 같은 숫자라고 성공한 별도 연장 최고 모델로 세지 않는다.

근거: suite_20260908_014452_72768a42/experiment_comparison.csv

Hair 6종: 원본·증강과 두 모델 구성

네 조건은 같은 6종 Validation 1,305장에서 비교했다. B0와 B1 사이의 여러 동반 설정은 본편의 설명을 따른다.

조건	Validation Accuracy	Validation Macro F1
b0_256_augmented	0.7777777777777778	0.7819142733310591
b0_256_original	0.7693486590038314	0.7729052037575177
b1_384_augmented	0.7931034482758621	0.8019837806385383
b1_384_original	0.7992337164750958	0.8144942091318823

조건 해석

B0는 증강이 높았고 B1은 원본이 높았다. 사진 수와 클래스 가중치·업데이트 수의 차이도 기록돼 있어 증강 하나의 순수 효과로 전부 분리하지 않는다.

양호 평가

새 양호 Validation과 Test는 각각 53장이다. 성능 우선 후보의 Test 양호 정답은 49/53이며 작은 특정 자료에서의 결과다. 전체 분류 성능과 양호 라벨의 정의를 따로 읽는다.

근거: benchmark.csv, Hair6 원본 결과 및 후보 selection.json

보존한 선정 버전 7개와 정확한 평가값

현재 기본 통합 경로와 과거 선정 버전, 별도 6종 역할을 나눠 보존한다.

선정 버전	Validation Accuracy	고정 Test Accuracy
Skin v1	0.982	0.9871428571428571
Web Skin v1	0.796	0.8825
Web Skin v2	0.85	0.915
Hair5 v1	0.7771565318107605	0.7883386581469649
Hair5 v2	0.7963258785942492	0.8003194888178914
Hair6 성능 우선	0.7992337164750958	0.7915708812260537
Hair6 경량	0.7777777777777778	0.7869731800766283

선정 버전	Test Macro F1
Skin v1	0.9871314132317626
Web Skin v1	0.8813822927981046
Web Skin v2	0.9141049081029712
Hair5 v1	0.7885764577048346
Hair5 v2	0.8002222282821301
Hair6 성능 우선	0.8091500773460419
Hair6 경량	0.8021613486071133

숫자의 출처

위 값은 각 폴더의 selection.json에서 직접 읽었다. 다른 과제의 정확도를 한 순위로 매기지 않는다. Hair5/6은 출력 클래스와 Test가 다르다.

근거: results/*/selected_models/*/selection.json

실행 비용: 정확한 p50과 파일 크기

기존 Validation과 후속 실행 시간의 결합 해석이다. 과거 학습 시간을 같은 GPU의 공정한 속도 순위로 쓰지 않는다.

조건	end-to-end p50 (ms)	checkpoint bytes
skin / augmented	282.2758660004183	17198406
web_skin / pmg_b0_256_ce_seed_42	304.2439384998943	36377179
web_skin / pmg_b1_384_ce_seed_42	419.9053944998923	46828176
hair5 / multires_b1_384_seed_42	407.29406550008207	47219220
hair6 / b0_256_augmented	288.73898249958074	29005042
hair6 / b1_384_original	409.83297050024703	47234592

절충의 실제 사례

Web PMG B1·384는 검증 성능 선두지만 지연이 길다. Hair6 성능 우선과 경량도 같은 과제 안에서 역할을 나눴다. 이 숫자를 실제 카메라 전체 앱이나 Jetson의 검증값으로 바꾸지 않는다.

전체 raw 기록

정확한 p95·모델 지연·로드 시간·파라미터 bytes·과거 학습 시간은 results/runtime_benchmark_20260928_051423/benchmark.csv에 있다. 표의 원본 문자열을 반올림하지 않았다.

근거: benchmark.csv. RUNTIME_BENCHMARK_REVIEW_20260928.md

34개 저장·측정 조건: Skin 10종

이 과제의 측정 조건 4개. 같은 실험의 보고서·그래프 생성은 새 학습으로 세지 않는다. 연장 학습과 예측 앙상블 검토는 전체 연구에 별도로 존재한다.

원본 experiment ID	Validation Accuracy	Validation Macro F1
augmented	0.982	0.9820008885656606
original	0.973	0.9730455448862949
initial_b0_224_original	0.9950000047683716	미기록
initial_b0_224_augmented	0.9950000047683716	미기록

이 표의 범위

34개는 이번 실행 비용 측정에서 불러온 저장 조건 수다. 34번만 연구했고 나머지는 없었다는 뜻도, 이 PDF를 만들며 34개를 다시 학습했다는 뜻도 아니다. 모든 행의 시간 측정 상태는 measured였다.

근거: results/runtime_benchmark_20260928_051423/benchmark.csv

34개 저장·측정 조건: Web Skin 5종

이 과제의 측정 조건 12개. 같은 실험의 보고서·그래프 생성은 새 학습으로 세지 않는다. 연장 학습과 예측 앙상블 검토는 전체 연구에 별도로 존재한다.

원본 experiment ID	Validation Accuracy	Validation Macro F1
b0_224_ce	0.794	0.7917009497301795
b0_256_ce	0.796	0.7915394647566528
b0_256_focal15	0.792	0.7898148816790076
b0_256_ls005	0.794	0.7892883497449976
b1_256_ls005	0.796	0.7931535064807589
mixstyle_b0_256_ce_seed_42	0.806	0.8033767539683495
pmg_b0_256_ce_seed_42	0.85	0.8473279632397033
wsdan_b0_256_ce_seed_42	0.764	0.7546949301321499
pmg_b1_384_ce_seed_42	0.866	0.8643216544321994
medsiglip_448_frozen_linear_seed_42	0.824	0.8195774288599683
initial_b0_224_original	미기록	미기록
initial_b0_224_augmented	미기록	미기록

이 표의 범위

34개는 이번 실행 비용 측정에서 불러온 저장 조건 수다. 34번만 연구했고 나머지는 없었다는 뜻도, 이 PDF를 만들며 34개를 다시 학습했다는 뜻도 아니다. 모든 행의 시간 측정 상태는 measured였다.

근거: results/runtime_benchmark_20260928_051423/benchmark.csv

34개 저장·측정 조건: Hair 5종

이 과제의 측정 조건 14개. 같은 실험의 보고서·그래프 생성은 새 학습으로 세지 않는다. 연장 학습과 예측 앙상블 검토는 전체 연구에 별도로 존재한다.

원본 experiment ID	Validation Accuracy	Validation Macro F1
baseline_b1_256_seed_42	0.7755591054313099	0.7746028470442391
supcon_b1_256_seed_42	0.7915335463258786	0.7910880666407202
dinov2_small_224_seed_42	0.7699680511182109	0.7705341251195019
efficientnetv2s_256_seed_42	0.7691693290734825	0.7681559382466019
multires_b1_384_seed_42	0.7963258785942492	0.7957146810115047
sam_b1_384_seed_42	0.7963258785942492	0.7954748920799393
medsiglip_448_frozen_linear_seed_42	0.7699680511182109	0.7687534259685547
clean_two_stage_20260907_061005	0.7643769979476929	미기록
clean_256_two_stage_20260907_064214	0.7699680328369141	미기록
clean_256_label_smoothing_005_20260907_103757	0.7739616632461548	미기록
clean_256_focal_gamma_15_20260907_105525	0.7675718665122986	미기록
clean_256_efficientnetb1_ls005_20260907_111711	0.7763578295707703	미기록
initial_b0_224_original	0.7062069177627563	미기록
initial_b0_224_augmented	0.704827606678009	미기록

이 표의 범위

34개는 이번 실행 비용 측정에서 불러온 저장 조건 수다. 34번만 연구했고 나머지는 없었다는 뜻도, 이 PDF를 만들며 34개를 다시 학습했다는 뜻도 아니다. 모든 행의 시간 측정 상태는 measured였다.

근거: results/runtime_benchmark_20260928_051423/benchmark.csv

34개 저장·측정 조건: Hair 6종

이 과제의 측정 조건 4개. 같은 실험의 보고서·그래프 생성은 새 학습으로 세지 않는다. 연장 학습과 예측 앙상블 검토는 전체 연구에 별도로 존재한다.

원본 experiment ID	Validation Accuracy	Validation Macro F1
b0_256_augmented	0.7777777777777778	0.7819142733310591
b0_256_original	0.7693486590038314	0.7729052037575177
b1_384_augmented	0.7931034482758621	0.8019837806385383
b1_384_original	0.7992337164750958	0.8144942091318823

이 표의 범위

34개는 이번 실행 비용 측정에서 불러온 저장 조건 수다. 34번만 연구했고 나머지는 없었다는 뜻도, 이 PDF를 만들며 34개를 다시 학습했다는 뜻도 아니다. 모든 행의 시간 측정 상태는 measured였다.

근거: results/runtime_benchmark_20260928_051423/benchmark.csv

핵심 용어 사전 1

같은 단어가 코드·논문·발표에서 어떤 역할인지 확인하는 찾아보기다.

용어	뜻
Backbone	이미지에서 특징을 만드는 본체
Head	특징을 해당 과제의 답으로 바꾸는 끝부분
Embedding	입력의 특성을 나타내는 숫자 벡터
Logits	softmax 전의 출력 점수
Fine-tuning	사전학습 가중치를 새 과제에 조정
Linear probe	본체를 고정하고 선형 분류기로 특징 활용성을 확인
Checkpoint	학습 상태나 가중치를 저장한 파일
Manifest	파일·버전·해시 등 구성 기록
SHA-256	파일 내용의 지문으로 쓰는 해시
Leakage	평가에 학습 정보가 섞이는 문제
Domain Gap	학습과 사용 입력의 분포 차이
Calibration	모델 점수와 실제 정답 빈도의 대응 검증

외우는 요령

모든 단어를 따로 외우기보다 "무엇이 입력이고 무엇이 출력인가, 어느 가중치가 바뀌는가, 무엇으로 평가하는가"에 연결하면 이해하기 쉽다.

핵심 용어 사전 2

같은 단어가 코드·논문·발표에서 어떤 역할인지 확인하는 찾아보기다.

용어	뜻
IoU	두 상자의 교집합 면적 / 합집합 면적
TCP	도구의 위치를 정의하는 기준점
Episode	한 번의 시연·작업 단위
Policy	관측에서 행동을 정하는 함수
Closed-loop	새 관측·상태를 피드백하며 동작
Token	언어 모델이 읽고 쓰는 텍스트 조각
SFT	검수된 정답 응답으로 지도 미세조정
LoRA	고정 본체 위 작은 저랭크 변화량 학습
QLoRA	양자화한 기반 모델과 LoRA를 이용한 학습
RAG	검색한 근거 문서를 생성 입력에 결합
Adapter	기반 모델에 더해 쓰는 추가 학습 가중치
Revision	기반 모델·데이터의 특정 버전 식별

외우는 요령

모든 단어를 따로 외우기보다 "무엇이 입력이고 무엇이 출력인가, 어느 가중치가 바뀌는가, 무엇으로 평가하는가"에 연결하면 이해하기 쉽다.

논문·공식 문서 1

각 제목의 링크를 누르면 원문 또는 공식 설명으로 이동한다. 논문 자체의 성능과 프로젝트 실험 수치는 구분한다.

R01

EfficientNet, Tan & Le, ICML 2019

https://proceedings.mlr.press/v97/tan19a.html

R02

Keras: Transfer learning & fine-tuning

https://keras.io/guides/transfer_learning/

R03

Rethinking the Inception Architecture, CVPR 2016

https://arxiv.org/abs/1512.00567

R04

Focal Loss for Dense Object Detection, ICCV 2017

https://arxiv.org/abs/1708.02002

R05

Supervised Contrastive Learning, NeurIPS 2020

https://arxiv.org/abs/2004.11362

R06

DINOv2: Learning Robust Visual Features, 2023

https://arxiv.org/abs/2304.07193

근거: 링크 확인 2026-10-28. AI Hub 71864·71863 본문은 이전 조회에서 미수신, 프로젝트 출처 기록으로 유지.

논문·공식 문서 2

각 제목의 링크를 누르면 원문 또는 공식 설명으로 이동한다. 논문 자체의 성능과 프로젝트 실험 수치는 구분한다.

R07

EfficientNetV2, ICML 2021

https://proceedings.mlr.press/v139/tan21a.html

R08

Sharpness-Aware Minimization, ICLR 2021

https://arxiv.org/abs/2010.01412

R09

See Better Before Looking Closer: WS-DAN, 2019

https://arxiv.org/abs/1901.09891

R10

Progressive Multi-Granularity Training, ECCV 2020

https://arxiv.org/abs/2003.03836

R11

Domain Generalization with MixStyle, ICLR 2021

https://arxiv.org/abs/2104.02008

R12

Google MedSigLIP-448 model card

https://huggingface.co/google/medsiglip-448

근거: 링크 확인 2026-10-28. AI Hub 71864·71863 본문은 이전 조회에서 미수신, 프로젝트 출처 기록으로 유지.

논문·공식 문서 3

각 제목의 링크를 누르면 원문 또는 공식 설명으로 이동한다. 논문 자체의 성능과 프로젝트 실험 수치는 구분한다.

R14

Ultralytics YOLO11 official documentation

https://docs.ultralytics.com/models/yolo11/

R15

ACT: Learning Fine-Grained Bimanual Manipulation, 2023

https://arxiv.org/abs/2304.13705

R16

Attention Is All You Need, NeurIPS 2017

https://arxiv.org/abs/1706.03762

R17

LoRA: Low-Rank Adaptation of Large Language Models

https://arxiv.org/abs/2106.09685

R18

Hugging Face TRL: SFT Trainer

https://huggingface.co/docs/trl/main/en/sft_trainer

R19

QLoRA: Efficient Finetuning of Quantized LLMs

https://arxiv.org/abs/2305.14314

근거: 링크 확인 2026-10-28. AI Hub 71864·71863 본문은 이전 조회에서 미수신, 프로젝트 출처 기록으로 유지.

논문·공식 문서 4

각 제목의 링크를 누르면 원문 또는 공식 설명으로 이동한다. 논문 자체의 성능과 프로젝트 실험 수치는 구분한다.

R20

AI Hub 71864, 피부종양 이미지 합성 데이터

https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71864

R21

AI Hub 71863, 안면부 피부질환 이미지 합성 데이터

https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71863

R22

AI Hub 216, 유형별 두피 이미지

https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=216

R23

Google MedGemma model card

https://developers.google.com/health-ai-developer-foundations/medgemma/model-card

R24

Retrieval-Augmented Generation, NeurIPS 2020

https://arxiv.org/abs/2005.11401

R25

Hugging Face PEFT: LoRA concepts

https://huggingface.co/docs/peft/main/en/conceptual_guides/lora

근거: 링크 확인 2026-10-28. AI Hub 71864·71863 본문은 이전 조회에서 미수신, 프로젝트 출처 기록으로 유지.

프로젝트 내부 근거와 상태 구분

프로젝트 기록은 발표 시점의 진행·후속 변경을 함께 읽어야 한다.

번호	내용	로컬 경로
D01	연구 방향	docs/ROADMAP.md; docs/research/PROJECT_BACKGROUND.md
D02	전체 상세 결과	docs/FINAL_DETAILED_REPORT_20260928.md
D03	방법별 이유·결과	docs/research/ALL_EXPERIMENTS_RATIONALE_AND_RESULTS_20260924.md
D04	Hair5/6 비교	docs/research/HAIR_5CLASS_6CLASS_EXPERIMENT_ANALYSIS_20260928.md
D05	실행 시간 해석	docs/research/RUNTIME_BENCHMARK_REVIEW_20260928.md
D06	팀 LLM/VLM 점검	docs/research/TEAM_LLM_VLM_REPOSITORY_REVIEW_20261026.md
D07	팀 발표와 해설	presentation/최종발표_70쪽_상세설명과_논문발표가이드_20261028.md
D08	LLM/VLM 연결 방향	docs/research/LLM_VLM_PROJECT_INTEGRATION_GUIDE_20261026.md

이번 책에서 하지 않은 것

새 학습·Test 재평가·GPU 벤치마크·로봇 제어·원격 배포를 수행하지 않았다. 원본 결과와 모델·노트북·발표자료를 수정하지 않았다. 팀 저장소 최신 원격 상태를 새로 점검한 것이 아니라 10월 26일 고정 기록과 코드 사본을 참고했다.

현재 상태와 앞으로 공부를 이어갈 순서

완료 결과를 이해한 뒤, 새 과제의 입력과 평가 기준을 준비한다.

완료된 연구의 중심

Skin·Web Skin·Hair 공개 데이터 후보, Hair6 별도 범위, 저장 모델 실행 비용 측정과 선정 버전을 정리했다. 실제 촬영 장비의 분류 성능과 목표 하드웨어 지연은 별도 확인 범위다.

다음 연구

설명 LLM은 실제 저장 결과와 문진을 읽는 평가부터 시작할 수 있다. 독립 VLM은 기존 클래스 정의와 분할을 유지해 사진 판단을 평가한다. 필요 오류가 확인된 뒤 검수한 자료로 추가 SFT를 설계한다. 본문은 다음 실험이 이미 실행됐다는 뜻이 아니다.

로봇과 통합

좌표·관절 추종과 단계별 파지·이동·투입을 반복 검증한다. 키오스크·분류기·LLM·VLM·로봇의 입력과 오류 상태를 명시하고 통합 성과는 별도로 평가한다.

이해 확인

질문: 발표를 한 문장으로 정리한다면?

답의 핵심: 데이터 특성과 같은 평가의 근거를 보고 방법을 비교했고, 잘 맞는 후보와 실행 비용을 확인한 뒤 다음 통합 과제를 준비하고 있다.

근거: ROADMAP 13·14단계 준비. 이번 PDF는 학습용 해설